


Klausurvorbereitung SoSe 2022

Zeitreihenanalyse

Zusammenfassung
Annalena Friedrich
(Version vom 9. Mai 2023)



Bildquelle: <https://xkcd.com/2201/>

Inhaltsverzeichnis

1 Statistik und Empirische Wissenschaft	6
1.1 Ziele der Vorlesung	6
1.2 Begrifflichkeiten etc.	6
2 Einführung in die Statistik	6
2.1 Deskriptive Statistik	6
2.2 Charakteristische Maßzahlen	7
2.3 Standardabweichung und Momente	7
3 Wahrscheinlichkeit	7
3.1 Vorgehen in der Praxis (Kolmogorov-Axiome der Wahrscheinlichkeitsrechnung) .	7
3.2 Unabhängigkeit	8
3.3 Bedingte Wahrscheinlichkeit	8
4 Zufallsvariablen	8
4.1 Wahrscheinlichkeitsdichte	9
4.2 Diskrete Verteilungsfunktionen	9
4.3 Gaußverteilung	10
5 Statistische Parameter	10
5.1 Varianz	10
6 kumulative Verteilungsfunktion	11
7 Grenzwertsätze	11
7.1 Gesetz der großen Zahl von Bernoulli	11
7.2 Zentraler Grenzwertsatz	11
8 Schätzer	11
8.1 Eigenschaften von Schätzern	12
8.1.1 Erwartungstreue	12
8.1.2 Effizienz	13
8.1.3 Konsistenz	13
8.2 Mittelwertschätzer	14
8.3 Varianzschätzer	14
8.4 Bias-Korrektur	14
8.4.1 Bias-Korrektur mittels Jackknife	14
8.5 Schätzung mit Maximum Likelihood-Methode	14
8.6 Intervall-Schätzer	15
8.7 Konfidenzintervalle	16
8.7.1 Beispiel 1	16
8.7.2 Beispiel 2 - von fundamentaler Bedeutung	16
8.7.3 Beispiel	17
8.7.4 Konfidenzintervalle zur Erfolgswahrscheinlichkeit der Binomialverteilung	17
8.7.5 Gaußsche Näherung	18

8.7.6	Konfidenzintervallschätzung durch Bootstrapping	18
8.8	Grundidee des Bootstrappings	18
8.8.1	Bootstrapping-Routine	18
9	Hypothesentests	19
9.1	Anwendung	19
9.1.1	Andere Sichtweise	20
9.1.2	Kalibrierte Sprache	20
9.2	Spezialfall Gaußverteilung	20
9.3	Zum Münzwurf	21
9.4	Zwei Testverfahren	21
9.4.1	Kolmogorov-Smirnow-Test	21
9.4.2	Chi-Quadrat-Test	21
9.5	Erweiterung des Tests auf parametrische Verteilungen	23
9.6	Gültigkeitsvoraussetzungen	25
10	Ist die Zeitreihe unkorreliert?	26
11	Der p-Wert	26
12	Lineare Regression	26
12.1	Methode der kleinsten Quadrate	27
12.2	Schätzer	27
12.3	Interpretation	27
12.4	Konfidenzintervall für Steigung	27
12.5	Konfidenzintervall für Vorhersage	28
12.6	Interpretation des Intervalls	28
13	Der Korrelationskoeffizient	28
13.1	Umgang mit multivariaten Verteilungen	28
13.2	Kovarianz und Korrelationskoeffizient	28
13.3	Multivariate Gaußsche Dichte-Verteilung	29
13.4	Interpretation Korrelationskoeffizient	29
13.5	Erklärte Varianz	29
13.6	Invarianz unter affinen Transformationen	29
13.7	Schätzung des Korrelationskoeffizienten	29
13.8	Konfidenzintervall für Korrelationskoeffizienten	30
13.9	Einige Merkgeln	30
13.10	Methode der kleinsten Quadrate nicht robust gegen Ausreißer	30
13.11	Vorteile der Methode der kleinsten Quadrate	30
14	Bootstrapping von linearer Regression	30
14.1	Bootstrapping	30
14.2	Bootstrapping von linearer Regression	31

15 Multivariate lineare Regression	31
15.1 Design-Matrix-Formulierung	31
15.1.1 Schätzer für das multivariat-lineare Modell	32
15.1.2 Wie viel der Varianz in Y wird dadurch geklärt?	32
15.1.3 Schätzung der Varianz der Residuen	32
15.2 F-Verteilung	32
15.3 Multivariate lineare Regression ohne Offset	33
15.4 Änderungen gegenüber dem Fall mit Offset a_0	33
15.5 Fingerprinting	33
15.6 Detection und Attribution	33
16 Zeitreihen	34
16.1 Zusammenhang Zeitreihe und Dynamischer Fluss	34
16.2 Beobachtungs-Rauschen	35
16.2.1 Gegenbeispiel	35
16.3 AR1-Prozess	35
16.3.1 Ansatz 2 für AR1: Erst Taylor, dann Diskretisierung:	36
16.4 Übersicht der Näherungen 3 für AR1	36
16.5 Übersicht der Näherungen 4	37
16.6 Übersicht der Näherungen 5	37
16.6.1 Varianz des 1D-AR1-Prozesses	37
16.7 Sattelknoten-Bifurkation	37
17 Wie gelangt man zu einer 1D Zeitreihe?	39
17.1 Einschub: Wie geht man mit hochdimensionalen Zeitreihen um?	39
17.1.1 Schätzung der Kovarianzmatrix	39
17.1.2 Zur EOF-Analyse	39
17.1.3 EOF Analyse im Kontext Sattelknoten-Bifurkation	42
17.1.4 Ablaufplan EOF-Analyse	42
17.2 Autokovarianz-Funktion	43
17.2.1 Autokorrelation von weißem Rauschen	43
17.2.2 Auto-Korrelation eines AR1 Prozesses	43
17.2.3 Schätzer	43
17.2.4 Wie schätzt man den Propagator c	43
17.2.5 Ist Zeitreihe unkorreliert - Durbin-Watson Test	43
17.2.6 Nachtrag: Wie prüft man, ob ein Fixpunkt stabil ist?	43
18 Altklausurfragen	45
18.1 Grundlagen der Statistik - Welche der Aussagen sind korrekt?	45
18.2 Konfidenzintervalle	46
18.3 Skalierung (2P.)	48
18.4 Lineare Regression	48
18.5 AR1-Prozesse und Bifurkationen	51
18.6 Bootstrapping	53
18.7 Hypothesentests	53
18.8 Chi 2 Test	53

19 Persönliche Auswahl	54
19.1 Unsicherheiten	54
19.2 Poissonverteilung	54
19.3 Zentraler Grenzwertsatz	54
19.4 Jackknife Bias-Korrektur	54
19.5 Schätzung mit Maximum Likelihood-Methode	55
19.6 Pearson-Clopper-werte	55
19.7 Chi 2 Test	55
19.8 Durbin-Wason-Test	56
19.9 White Noise	56
19.10 Motivation AR1-Prozesse	56

1 Statistik und Empirische Wissenschaft

1.1 Ziele der Vorlesung

- Elementare statistische Rechnungen durchführen
- Statistische Informationen einordnen können
- Programmierfähigkeiten erweitern

1.2 Begrifflichkeiten etc.

Was ist **Zeitreihenanalyse**?

- Statistik von Messreihen, die entlang der Zeitachse erhoben wurden
- deutet of einfaches (dynamisch-) stochastisches Modell in Zeitreihen hinein, kann zur vorbereitenden Datenreduktion genutzt werden
- auch Wirklichkeit entwickelt sich in der Zeit
- wichtig in Wissenschaften, wo alle Modelle dynamische Modelle sind, also Entwicklungen entlang der Zeitachse prognostizieren
- dient dazu, Dinge zu sehen, die man sonst nicht sehen könnte, beobachtet, beschreibt und bildet Theorien über Beobachtetes
- **Stochastische Prozesse**: solche, die zufallsgetrieben sind oder sich näherungsweise so verhalten, können mit Hilfe der Wahrscheinlichkeitstheorie beschrieben werden
- **deskriptive Statistik**: ableiten von Kenngrößen und Identifikation von Mustern
- **induktive Statistik** man nutzt die deskriptive Statistik um Verborgenes herauszufinden
- **Unsicherheit**: alle Formen des Nicht-Wissens
- **aleatorische Unsicherheit**: Nicht-Wissen, das durch stochastische Prozesse ausgelöst wird, kann nicht reduziert werden, Beispiel: Chaos im Wettersystem trägt zur Unsicherheit der Wettervorhersage bei
- **epistemische Unsicherheit**: Übrige Unsicherheit, bezeichnet häufig statische Größen, die wir aber nicht genau kennen, kann durch Forschung reduziert werden

Anwendungen von Statistik:

- Variablen nicht direkt zugänglich, sondern verrauscht, versuchen das 'Original' zu rekonstruieren
- Modell und/oder reales System werden durch stochastische Prozesse getrieben, benötigen Statistik um beide in Beziehung zu setzen

Entwicklung der Computer erlaubt es, Auswertungen von Messreihen automatisiert auszuführen.

2 Einführung in die Statistik

2.1 Deskriptive Statistik

zufälliger oder zufallsartiger Vorgang, der durch konstante Rahmenbedingungen geprägt ist, dann:

- ↙ • Auftreten von Wirkungen, die **Ereignisse** genannt werden

- Zahlenwerte heißen Merkmalswerte oder Daten
- Häufigkeit ist Anzahl numerisch gleicher Zahlenwerte, Häufigkeitsverteilung ist Zuordnung dieser zu den Merkmalen
 - Zusammenstellung aller möglichen Ereignisse ist Grundgesamtheit oder Population
 - zufällig beobachtete Ereignisse bilden Stichprobe, Zahl dieser Ereignisse heißt Stichprobenumfang (n)

Geordnete Darstellung

Es gibt sowohl die Häufigkeitsverteilung als auch die kumulierte Häufigkeitsverteilung. X-Achse bezeichnet die Abszisse und die y-Achse die Ordinate. Die relative Häufigkeit kann nur maximal 1 sein, die relative kumulierte Häufigkeit 100 %.

Selber generieren:

- > Schnittlänge / Intervallgröße (individuell)
- > Messwerte in bins → Unsicherheit (bins ohne Einheit)
- > konn. Verlauf bei feiner Vert.

Stabilität y-Achse

kontinuierl. x-Achse

2.2 Charakteristische Maßzahlen

- **Arithmetisches Mittel:** $\langle a \rangle := \frac{1}{n} \sum_{i=1}^n a_i$
- **Modus:** Gipfelwert der Häufigkeitsverteilung, häufigster Wert
- **Median:** Wert, an dem relative kumulierte Häufigkeitsverteilung der Wert $\frac{1}{2}$ annimmt

Bis zu welchem Punkt aufsummieren um 50% zu erhalten

→ keine Willkür

Bei symmetrischen eingipfeligen Häufigkeitsverteilungen gilt stets:

$$\langle a \rangle = \text{Median} = \text{Modus}$$

Im Fall von unsymmetrischen aber eingipfeligen Verteilungen gilt dagegen:

$$\langle a \rangle < \text{Median} < \text{Modus}$$

oder

$$\langle a \rangle > \text{Median} > \text{Modus}$$

Der Median liegt also in beiden Fällen zwischen den beiden anderen Maßen.

Median: nicht abh. v. y-Achse

↳ robuster

→ Bei Unfall in Messung

Quantile:

p-Quantil: Lokalisierungsmaß, an dem die relative kumulierte Häufigkeit p misst. Eine Abbildung dazu:

Meist zw. 10 u. 90% (für 10%: kumul. Wahrs. zeichnen, durch n teilen, bei 10% ablesen)

Kumuliert:

An jedem Punkt: wieviele Einträge von Punkt bis links

2.3 Standardabweichung und Momente

Standardabweichung:

Schwankung um Zentralbereich

$$s := \left(\frac{1}{n-1} \sum_{i=1}^n (a_i - \langle a \rangle)^2 \right)^{1/2} \quad (2.1)$$

k-tes zentrales Moment:

$$\frac{1}{n} \sum_{i=1}^n (a_i - \langle a \rangle)^k, k > 1 \quad (2.2)$$

3 Wahrscheinlichkeit

3.1 Vorgehen in der Praxis (Kolmogorov-Axiome der Wahrscheinlichkeitsrechnung)

- allen N Elementarereignissen wird dieselbe Wahrscheinlichkeit zugewiesen
- Die Wahrscheinlichkeit eines Ereignisses A ist die relative Häufigkeit derjenigen Elementarereignisse am Gesamt ereignis, die A aufbauen: $P(e_1, \dots, e_n) = \frac{n}{N}$




Abbildung 1: Zur Definition der Quantile (Fraktile) einer Verteilungsfunktion

3.2 Unabhängigkeit

Zwei Ereignisse A und B eines Wahrscheinlichkeitsfeldes heißen genau dann unabhängig voneinander, wenn

$$P(A \text{ geschnitten } B) = P(A)P(B) \quad \rightarrow \text{Schwankungen sind unabhängig voneinander}$$

$$P(A \cap B)$$

3.3 Bedingte Wahrscheinlichkeit

- **Bedingte Wahrscheinlichkeiten** setzen das Eintreten eines bestimmten Ereignisses voraus, bevor das eigentliche Ereignis eintritt

$$P(A|B) := \frac{P(A \text{ geschnitten } B)}{P(B)} \quad \text{Wahrs. für A mit Nebenbed. B} \quad (3.1)$$

Das Ereignis A wird somit im Unterraum B bewertet.

Satz von Bayes:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad \text{Bedingte Wahrs. A} \quad \begin{array}{l} P(B) = \frac{2}{3} \\ P(A|B) = \frac{1}{4} \rightarrow \text{Engerer Bereich B} \\ P(A \cap B) = \frac{1}{6} \end{array} \quad (3.2)$$

Außerdem gilt:

$$P(A \text{ geschnitten } B) = P(A)P(B|A) \quad (3.3)$$

4 Zufallsvariablen

- Mengen, die einen Zufallsprozess beschreiben

$$X = \{(x, P(x)), x \in \Omega\} \quad (4.1)$$

$$\text{Bsp } \Omega = \left\{ \overset{1/2}{\text{Kopf}}, \overset{1/2}{\text{Zahl}} \right\}$$


- x ist das Ereignis, $P(x)$ die Wahrscheinlichkeit für das Ereignis und Ω der Stichprobenraum
- Verteilungsgrößen können diskret oder kontinuierlich sein
- Beispiel diskret: "Kopf oder Zahl"- Experiment, führend auf $1/2, 1/2$ als Verteilungsfunktion
- Beispiel kontinuierlich: Gaußverteilung: $X_N = \{(x, N(x, 0, 1)), x \in (-\infty, \infty)\}$

4.1 Wahrscheinlichkeitsdichte

- **Wahrscheinlichkeitsdichte** f erlaubt es, die Wahrscheinlichkeit für ein Intervall wie folgt zu berechnen: $P(a \leq X \leq b) = \int_a^b f(x) dx$

- bekannte kontinuierliche Wahrscheinlichkeitsdichtefunktionen:

- Gleichverteilung
- Normalverteilung
- X^2 -Verteilung
- Student-t-Verteilung
- Fischer-F-Verteilung



Variable auf reeller Achse
↳ überabzählbar viele Ereignisse

$f(x)$: Funktion

↳ Wahrs. im Intervall

$P(a \leq x \leq b) = \int_a^b f(x) dx$ z.B. in mg gemessen

$[f] = \frac{1}{m}$, denn $p = 1 = f \cdot dx = \frac{1}{m} \cdot m = 1$

4.2 Diskrete Verteilungsfunktionen

$\binom{n}{x} = \frac{n!}{x!(n-x)!}$

$p+q=1$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

$P_{n,p}(x) = \binom{n}{x} p^x \cdot q^{n-x}$

→ kleinere Trefferwahrs.

$p: p \rightarrow 0$

→ höhere Versuchszahl

$n: n \rightarrow \infty$

$\lambda = p \cdot n = \text{const}$

- **Binominalverteilung**, Voraussetzungen:

- Versuche und Resultate der Versuche sind unabhängig voneinander
- für jeden Versuch bleibt die Wahrscheinlichkeit eines Ereignisses konstant

- **Poissonverteilung**: beschreibt Verteilung von seltenen Einzelereignissen. Voraussetzungen:

- sind wirklich Einzelereignisse (z.B. Erdbeben)
- Proportionalität: Länge des Zeitraums bestimmt die Wahrscheinlichkeit des Ereignisses
- Homogenität: Unabhängigkeit von der Zeit
- Unabhängigkeit: Ereignisse hängen nicht von einander aber

Poissonverteilung:

$$f_P(x) = \frac{(\lambda t)^x}{x!} \exp^{-\lambda t} \quad \text{Intervall} \quad (4.2)$$





Abbildung 2: diskrete und kontinuierliche Darstellung

4.3 Gaußverteilung

- Grundlage vieler statistischer Theorien
- Beispiel der Exponentialverteilungen

Formel der Normalverteilung:

Momente: $m_1 = \mu \rightarrow$ Maximum
 $m_2 = \sigma^2$
 $m_3 = 0$ Schräge
 $m_4 = 3$ Wölbung

Gleichverteilung:
Flache vert., jede Zahl gleich wahrs.

Student-Vert.
→ exakte Konfidenz-Verteil.

Normal, üblich:
→ Maximum bei μ
→ σ Breite der Kurve

Standard-Normal
 $\mathcal{N}(\mu, \sigma) = \mathcal{N}(0, 1)$ (4.3)

$$f_N(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Skalieren, Verstärkung, Parabel, Maximum, Breite

5 Statistische Parameter

- Normalverteilung: definiert durch Standardabweichung σ und Mittelwert μ
- $\mathcal{N}(\mu, \sigma) = \mathcal{N}(0, 1)$ wird als Standard-Normalverteilung bezeichnet
- affine Transformationen führen wieder zu Normalverteilung
- Verteilung wird durch einzelne Charakterisierungen beschrieben:
- Momente:
 - k-tes Moment einer pdf $f(x)$:

0-tes Moment immer 1
ungerade Mom. immer 0

Mittelwert berechnen

wo?

$$m_k = \int_a^b x^k f(x) dx$$

Gauß-Vert: $a \rightarrow -\infty, b \rightarrow +\infty$

(5.1)

- k-tes zentriertes Moment (zentrale Momente beziehen sich auf die Gestalt der Verteilung, bezogen auf den Mittelwert), einer pdf mit m_1 ist auch Erwartungswert $E(X)$ (für X, Y Zufallsvariablen auf Gesamt ereignis gilt: $E(X+Y) = E(X) + E(Y)$):

Wie sieht sie aus?

$$\mu_k = \int_a^b (x - m_1)^k f(x) dx$$

Abw. v. Mittelwert

(5.2)

- Mittelwert: $m_1 = \mu$, wird auch als Erwartungswert $E(x)$ bezeichnet. Es gilt: $E(X') = E(aX + b) = aE(X) + b$. (Er liefert uns die Lage der Verteilung) Das erste zentrale Moment ist 0.
- Varianz: $\mu_2 = \sigma^2$
- Schräge: $\mu_3 = 0$
- Wölbung: $\mu_4 = 3$
- alle ungeraden Momente sind null
- Erwartungswert gegeben:
 - bei aff. Transf. (lineare Abb.)
 - multipliz. v. X , dehnen u. umschreiben von Verteilung
 - neuer EW. alt. EW. modifiz. mit selber aff. Abb.
- Quantile:
 - Quantil x_p ist der Wert, an dem der Anteil p der Wahrscheinlichkeit erreicht wurde
 - $p = 0.5$ (Median)
 - $p = 0.25$ oder $= 0.75$ (Quartile)
 - $p = 0.01, 0.05, 0.95, 0.99$ (Perzentile)

F^{-1} auf p anwenden
 $F(x_p) = p$

5.1 Varianz

- $\mu_2 = \sigma^2$ ist die Varianz $Var(X)$, mit σ = Standardabweichung (auch Streuung genannt)

- es gilt: $Var(X) = E((X - E(X))^2)$ und $Var(X) = E(X^2) - (E(X))^2$ (Steinerscher Satz) und $Var(cX) = c^2 Var(X)$ und $Var(X + c) = Var(X)$ und wenn X, Y unabhängig gilt außerdem: $Var(X + Y) = Var(X) + Var(Y)$
- 2. zentrales Moment hier m_2*
1. zentrales Moment
nach rechts verschoben um c
 X, Y unabhängig

verdoppeln der Zufallsgröße:
vervielfachen der Varianz

zentrale Momente nur über
Gestalt
→ Verschiebung links/rechts
bleibt Var erhalten

6 kumulative Verteilungsfunktion

- Integral über pdf:

$$F(x) = \int_{-\infty}^x f_x(r) dr \quad (6.1)$$

- man erhält von x abhängige Funktion
- pdf auf 1 normiert, daher verläuft Funktion von 0 nach 1

7 Grenzwertsätze

7.1 Gesetz der großen Zahl von Bernoulli

- bei häufiger Wiederholung eines Zufallsexperiments können die relativen Häufigkeiten durch Wahrscheinlichkeiten angenähert werden

7.2 Zentraler Grenzwertsatz

Annahmen:

- Zufallsvariablen X_k sind i.i.d (independent and identically distributed)
- $E(X_k) = \mu$ und $Var(X_k) = \sigma^2$
- Dann gilt:

$$\lim_{n \rightarrow \infty} \left(\frac{\frac{1}{n} \sum_{k=1}^n (X_k - \mu)}{\frac{1}{\sqrt{n}\sigma}} \right) \sim \mathcal{N}(0, 1) \quad (7.1)$$

- Summe einer sehr großen beliebig verteilten Zufallsvariablen konvergiert gegen die Normalverteilung
- Auf Grenzwertsatz beruht die Wichtigkeit der Normalverteilung

8 Schätzer

- statistische Schätzverfahren (Methoden, die geeignet erscheinen, von einer bekannten Stichprobe auf entsprechende Informationen der unbekannten Grundgesamtheit zu schließen)
- Punktschätzung:** Näherungsberechnung der Kenngröße
- Intervallschätzung:** Konfidenzintervalle der Kenngröße

Zusammensetzen von Daten
und theoretischen Funktionen

↳ aus verrauschten Daten etwas genaues rausbekommen
durch induktive Statistik

8.1 Eigenschaften von Schätzern

8.1.1 Erwartungstreue

- Schätzer heißen erwartungstreu, unverzerrt oder unverfälscht (unbiased), wenn der Erwartungswert des Schätzers gleich dem entsprechenden Wert der Grundgesamtheit ist
- der **Bias** B eines Schätzers $\hat{a}$ ist definiert als: $B(\hat{a}) := E(\hat{a}) - a$ für erwartungstreuen Schätzer soll das 0 sein

↓
Dach = Schätzer

Abweichung

|
Geschätzter
wert

$a = \text{wahrer Wert}$

Erwartungswert eigentlich Integral aber
annähernd durch arithm. Mittel

Beispiele für erwartungstreue Schätzer: *nur durch n teilen
verzerrter Schätzer*

*auswert-
dig*

	Schätzer	Wahrer Wert <i>kontinuierl. Verteilung</i>	Wahrer Wert <i>diskrete Verteilung</i>
Arithmetisches Mittel	$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n X_k$	$\mu := \int_{-\infty}^{\infty} f(x) x \, dx$	$\mu := \sum_{i=1}^n p_i x_i$
Varianz	$\frac{1}{n-1} \sum_{k=1}^n (X_k - \hat{\mu})^2$	$\int_{-\infty}^{\infty} f(x) (x - \mu)^2 \, dx$	$\sum_{i=1}^n p_i (x_i - \mu)^2$
Kumulierte Verteilung	$\frac{\text{Zahl der Werte} < x}{n}$	$\int_{-\infty}^x f(x') \, dx'$	$\sum_{i: x_i \leq x} p_i$

Abbildung 3: erwartungstreue Schätzer

wichtig: Arithmetisches Mittel ist der Schätzer und Erwartungswert ist der Wahre Wert. Außerdem gilt der wahre Wert nur für die kontinuierliche Verteilung. Für die diskrete Verteilung hat man Summen statt Integrale und geht von $i = 1$ bis n .

8.1.2 Effizienz

- Schätzer $\hat{a}$ heißt effizienter als ein anderer Schätzer $\hat{b}$ des wahren Wertes a , wenn der erwartete **quadratische Fehler** geringer ist:

$$E(\hat{a} - a)^2 < E(\hat{b} - a)^2 \quad (8.1)$$

- Es kann gezeigt werden:

$$E(\hat{a} - a)^2 = (B(\hat{a}))^2 + \text{Var}(\hat{a}) \quad (8.2)$$

mittlere quadratische Schwankung setzt sich also aus Bias und Schwankung zusammen

- der effizienteste Schätzer wird dann **effizient** genannt

8.1.3 Konsistenz

- Schätzer heißt konsistent, wenn für eine gegen unendlich laufende Anzahl von Stichprobenelementen der **mittlere quadratische Fehler** gegen **null** läuft:

$$\lim_{n \rightarrow \infty} E(\hat{a} - a)^2 = 0 \quad (8.3)$$

- Da $E(\hat{a} - a)^2 = (B(\hat{a}))^2 + \text{Var}(\hat{a})$ bedeutet dies auch asymptotische Erwartungstreue (Schätzer ist für erheblich große Stichproben erwartungstreu, nicht aber für kleinere)

Das Ideal für einen Schätzer ist dann, dass er **unverzerrt**, **konsistent** und **effizient** ist.

8.2 Mittelwertschätzer

- arithmetisches Mittel ist Schätzer für das erste Moment, siehe 3, er ist unverzerrt und konsistent, ist unter allen gewichteten Mitteln der effiziente, Beispiel: siehe Folien und Übungsaufgabe, dort musste man besagte Folie zusammenfassen, Am wichtigsten: Wenn wir x messen wollen, aber einen Rauschterm hinzuaddieren müssen und somit stattdessen $Y = x + \epsilon$ erhalten, genügt Y einer Gaußverteilung mit dem Mittelwert x . Wenn wir dann eine Stichprobe von Y nehmen und davon das arithmetische Mittel bilden, erhalten wir eine sinnvolle Schätzung für x .

8.3 Varianzschätzer

- der einfachste Varianzschätzer ist verzerrt aber effizienter:

$$\frac{1}{m} \sum_{i=1}^m (X_i - \hat{\mu})^2 \quad (8.4)$$

- der nächste ist unverzerrt aber weniger effizient:

$$\frac{1}{m-1} \sum_{i=1}^m (X_i - \hat{\mu})^2 \quad (8.5)$$

mindest Anzahl
Messpunkte: 2

8.4 Bias-Korrektur

Übergang von einem Schätzer mit Bias zu einem ohne Bias.

Heißt die Korrektur wird von einem verzerrten Schätzer abgezogen.

8.4.1 Bias-Korrektur mittels Jackknife

- für besagte Korrektur benötigen wir zuerst die Hilfsgröße $\hat{a}_j := \frac{1}{n} \sum_{k=1}^n \hat{a}_k$, wobei $\hat{a}_k$ heißt, dass der k 'te Messpunkt weggelassen wurde
- für die Korrektur ergibt sich dann:

$$\widehat{\nabla a} := (n-1)(\hat{a}_j - \hat{a}) \quad (8.6)$$

8.5 Schätzung mit Maximum Likelihood-Methode

- bisherige Schätzverfahren funktionieren
- Methode liefert systematische Methode, um Allgemeineres über Verteilung erfahren zu können
- gemacht für Fälle, in denen Zufallsvariable X von Dichteverteilung $f(x; a)$ generiert wird, mit a unbekannt und soll geschätzt werden
- Angenommen: Messergebnisse $x_1, x_2, x_3, \dots$ sind aufgetreten, dann kann nach Gesamtwahrscheinlichkeitsdichte gefragt werden, dass genau diese Messreihe auftritt. Wenn Ereignisse unabhängig, lautet sie:

$$f(x_1, \dots, x_n; a) = \prod_{k=1}^n f(x_k; a) \quad (8.7)$$

- daraus kann Likelihood-Funktion konstruiert werden. Dafür sieht man nicht mehr x als Variable an, sondern a :

$$L(a; x_1, \dots, x_n) := f(x_1, \dots, x_n; a) \quad (8.8)$$

- zu beachten: Funktion nimmt dort ihr Maximum an, wo auch ihr Logarithmus es tut, damit erhält man folgende handlichere Formel:

$$\hat{a}_{ML} := \operatorname{argmax} \ln \prod_{k=1}^n f(x_k; a) \quad (8.9)$$

- Daher gilt: $\hat{a}_{ML} = \operatorname{argmax} \sum_{k=1}^n \ln f(x_k; a)$, dieser Schätzer ist konsistent

8.6 Intervall-Schätzer

Wenn man wissen möchte, wie sicher der beste Wert ist, den die bisherigen Methoden aus der Messreihe generieren. Dafür wurden die sogenannten Konfidenz-Intervalle erfunden.

Zur Veranschaulichung folgt ein Beispiel: Unter dem Konfidenzintervall, abgekürzt auch KI ge-

Beispiel: Konfidenz-Intervall zur Mittelwertschätzung

SZ, 90




Figure 5.4: Ten realizations of a 95% confidence interval for unknown parameter α . On average, 19 out of 20 intervals will cover α . In this example, $\alpha = 0$. The curve shows the density function of the sampled random variable.

Beispiel Konfidenzintervalle

nannt, ist ein statistisches Intervall zu verstehen, das die Lage eines wahren Parameters einer Grundgesamtheit mit einer gewissen Wahrscheinlichkeit lokalisieren soll.

Im Gegensatz zum geschätzten Parameter, der bekanntermaßen über Berechnungen mit den Daten einer Stichprobe zustande kommt, kann ein wahrer Parameter selten exakt bestimmt

werden. Konfidenzintervalle bieten aber zumindest die Möglichkeit, ihn mit einer gewissen Erfolgswahrscheinlichkeit genauer verorten zu können.

- wir wollen Eigenschaft a einer Messreihe bestimmen, zB. den Mittelwert einer Haußverteilung
- dann heißt $I := [\underline{a}, \bar{a}]$ genau dann ein p -Konfidenzintervall, wenn $P([\underline{a}, \bar{a}] \in a) = p$
- $\underline{a}$ und $\bar{a}$ sind hier Schätzer, deren numerische Werte von der jeweiligen Messreihe abhängen
- p üblicherweise nahe bei 1, $1 - p$ ist also $\ll 1$, um viel Sicherheit zu erzeugen

8.7 Konfidenzintervalle

Rezept zur Konstruktion eines Konfidenz-Intervalls

- definiere Punktschätzer $\hat{a}$ und leite Verteilung von $\hat{a}$ her
- transformiere $\hat{a}$ mit Hilfe von a so, dass die Verteilung f_z der Transformatierten $Z := h(\hat{a}, a)$ nicht mehr vom unbekannten a abhängt
- manchmal gibt es eine solche Transformatierte nicht exakt, sondern man kann nur erreichen, dass sie möglichst schwach von a abhängt
- definiere Intervall $I_z := [\underline{Z}, \bar{Z}]$, so dass $P(Z \in I_z) = p$
- je mehr Sicherheit man möchte, desto größer wird das Intervall

8.7.1 Beispiel 1

Konfidenzintervall für einen unbekannten Mittelwert μ einer Gaußverteilung bei deren bekannter Varianz σ^2 .

- Als Punktschätzer wählen wir das arithmetische Mittel $\hat{\mu}$ der Stichprobe
- wir betrachten die Hilfsgröße $Z := \hat{\mu} - \mu$
- sie ist als verschobene Summe von Gaußverteilungen wieder gaußverteilt
- ihr Mittelwert ist 0
- ihre Standardabweichung ist $\sigma_z = \frac{\sigma}{\sqrt{n}}$
- entscheiden wir uns nun für die Konfidenz p des $1 - \sigma$ -Bereichs einer Gaußverteilung $\approx 68\%$, können wir I_z wie folgt konstruieren: $I_z := [-\sigma_z, \sigma_z]$
- die Rücktransformierte ist dann (mit $\mu = \hat{\mu} - Z$):

$$P(\mu \in [\hat{\mu} - \sigma_z, \hat{\mu} + \sigma_z]) \approx 68\% \quad (8.10)$$


8.7.2 Beispiel 2 - von fundamentaler Bedeutung

Konfidenzintervall für einen unbekannten Mittelwert μ einer Gaußverteilung bei deren unbekannter, aber nicht interessanter Varianz σ^2 . Stichprobenumfang sei n . Ein Konfidenzintervall für den Mittelwert konstruiert man dann wie folgt:

- Man benötigt zuerst einmal die Schätzer für Mittelwert und Standardabweichung:

$$\hat{\mu} := \frac{1}{n} \sum_{k=1}^n X_k, \hat{s} := \sqrt{\left(\frac{1}{n-1} \sum_{k=1}^n (X_k - \hat{\mu})^2 \right)} \quad (8.11)$$

- wenn $n \geq 30$, wird meistens die **Näherungsformel** $I_{a\sigma} := [\hat{\mu} - \frac{a\hat{s}}{\sqrt{n}}, \hat{\mu} + \frac{a\hat{s}}{\sqrt{n}}]$ verwendet. a bestimmt man aus der Konfidenzwahrscheinlichkeit $p = 1 - \alpha$ und der Standard-Normalverteilung f , so dass $\int_{-a}^a f(x)dx = p$
- Standardfälle sind:
 - $a = 1$, dann $p = 68\%$
 - $a = 2$, dann $p = 95\%$
- wenn $n < 30$, sollte man die Student-Verteilung verwenden anstelle der Gaußverteilung, um das p - Konfidenzintervall zu bestimmen. Das folgende ist für alle n das exakte Verfahren:
 - Dann gilt: $I_{\text{exakt},p} = [\hat{\mu} - \frac{t_{a,m}\hat{s}}{\sqrt{n}}, \hat{\mu} + \frac{t_{a,m}\hat{s}}{\sqrt{n}}]$, mit $a := 1 - p$ (Irrtumswahrscheinlichkeit) und $m := n - 1$ (Zahl der Freiheitsgrade)
 - $\pm t_{a,m}$ bezeichnet die Intervallgrenzen der Studentverteilung mit m Freiheitsgraden, zwischen denen das Integral gerade p ergibt:



Student-Verteilung Konfidenzintervalle

Die t -Verteilung (=Student-Verteilung) geht für zunehmende Freiheitsgrade in die Gaußverteilung über.

Nebenbemerkung Dass diese Dichte nicht exponentiell, sondern algebraisch abfällt, hat Konsequenzen in der Klimaökonomie (fat tail der Klimawandelschäden als Funktion der Klimaseinitivität).

8.7.3 Beispiel

Für $n = 2$, d.h. 1 Freiheitsgrad, und einem Konfidenzniveau von 95% würde der Quotient aus exaktem Wert und gaußischem Grenzfall ca. 6 betragen!

Außerdem: William Sealy Gosset hat 1908 exaktes Konfidenzintervall für den Mittelwert einer Gaußverteilung bei kleinen Stichproben veröffentlicht. Student-Verteilung genannt, weil er sie unter dem Pseudonym Student veröffentlichte.

8.7.4 Konfidenzintervalle zur Erfolgswahrscheinlichkeit der Binomialverteilung

- n Versuche, x Treffer: Schätzer der Erfolgswahrscheinlichkeit p : $\hat{p} = \frac{x}{n}$
- für x, n geben die Pearson-Clopper-Werte die Konfidenzintervalle für p an
- Pearson-Clopper-Werte garantieren exakte Untergrenze der Konfidenz

8.7.5 Gaußsche Näherung

- wenn n groß genug, kann Binomialverteilung durch Gaußverteilung angenähert werden
- genähertes $(1 - \alpha)$ Konfidenzintervall $[p_-, p_+]$ für p :

$$p \pm z := \frac{h + \frac{z^2}{2n} \pm \sqrt{\frac{hz^2}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \quad (8.12)$$

- h : Gemessene relative Häufigkeit der Erfolgsergebnisse
- z : Das Quantil der Standardnormalverteilung, so dass rechts davon eine Wahrscheinlichkeit von $\frac{\alpha}{2}$ markiert wird

8.7.6 Konfidenzintervallschätzung durch Bootstrapping

Angenommen, wir wollen die Eigenschaft a einer Grundgesamtheit wissen. Die Ableitung exakter Konfidenzintervalle kann schwierig sein, wenn:

- die Analysis der Parameterschätzung einer ansonsten bekannten Wahrscheinlichkeits(dichte)verteilung schwierig ist (eine parameterunabhängige Transformierte (die dann z.B. Student-verteilt ist) schwer zu finden ist) oder
- die Wahrscheinlichkeits(dichte)verteilung gar nicht bekannt ist
 - in letzterem, sehr extremen Falle ergibt es dennoch Sinn, nach aggregierten Größen wie Mittelwert oder Varianz der Grundgesamtheit zu fragen

8.8 Grundidee des Bootstrappings

- besteht nun darin, die unbekannte oder unterbestimmte kumulierte Verteilung F unverzerrt zu schätzen durch die vorliegende, empirische Verteilung $\hat{F}$, gewonnen aus einer Stichprobe mit Umfang n
- dann können aus dieser approximierten kumulierten Verteilung Varianten der originalen Stichprobe generiert werden, die ebenfalls den Umfang n haben
- so erhält man einen Eindruck wie stark der Schätzer $\hat{a}$ schwankt, durch den Umstand, dass n endlich ist

8.8.1 Bootstrapping-Routine

1. bestimmen sie aus ihrer Stichprobe mit Umfang n eine Schätzung $\hat{F}$ der kumulierten Verteilung F
2. erzeugen sie eine **Bootstrap-Samples** Surrogat-Stichprobe $y_1, \dots, y_n$, indem sie aus der Original-Stichprobe n -mal mit Zurücklegen ziehen [n^n Kombinationen]
3. aus $y_1, \dots, y_n$ bestimmen sie $\hat{a}$
4. Vorgänge 2-3 werden N -mal wiederholt. Dadurch erhalten sie eine empirische Verteilung f_a für $\hat{a}$ [In der Praxis $N > 100$]
5. geben sie sich ihre Konfidenz p vor und wählen sie die Konfidenz-Intervallgrenzen $[\underline{a}, \bar{a}]$ für $\hat{a}$ so, dass $\int_{\underline{a}}^{\bar{a}} f_a(x) dx = p$

[Für $[\underline{a}, \bar{a}]$ ist Konf.-Interv. ca. $1-\alpha$, falls $\hat{F}$ konsist. Schätzer für F]

Alle Daten in Urne
Ziehen aus Urne (zurücklegen)
 n -mal durchführen
 N -Surrogat datensätze

Bemerkungen dazu:

- Surrogat-Stichproben heißen auch **Bootstrap-Samples**. Es gibt deren n^n Kombinationen und $\frac{n^n}{n!} \approx \frac{e^n}{\sqrt{2\pi n}}$ unterschiedliche Kombinationen
- in der Praxis, $N > 100$, für Konfidenzintervalle werden deutlich mehr benötigt, weil man in den Ausläufern von Verteilungen arbeitet. Dadurch entstehen auch Ansprüche an n . man kann zeigen, dass $[\underline{a}, \bar{a}]$ ein näherungsweise Konfidenzintervall für a ist.

9 Hypothesentests

- vor dem Experiment wird Nullhypothese H_0 und Alternativhypothese H_1 aufgestellt
- ist H_0 wahr, ist H_1 nicht mehr relevant *! für lineare Regression u. wissens. Arbeiten*

9.1 Anwendung

Es gibt vier mögliche Fälle die eintreten können:

Kontingenztafel

		Realität	
		H ₀ ?	
Test	W	✓	✗
	F	✗	✓


Kontingenztafel

Kontingenztafel

		Realität	
		H ₀ ?	
Test	W	hit	miss
	F	false alarm	correct rejection

Kontingenztafel

auswendig



Prozedur wie entschieden werden soll, muss feststehen bevor Daten gesichtet werden
→ Fehler 1. u. 2. Art vorher festlegen

a: wieviel der Verteilung liegt außerhalb meines gemessenen Werts

H_0 verwerfen wenn X außerhalb des 95% Intervalls von H_0 liegt

Kontingenztafel

		Realität	
		$H_0?$	
Test	W	1- α	β
	F	α	1- β

α : Fehler 1. Art, Irrtumswahrscheinlichkeit=1-Signifikanz(niveau)
 β : Fehler 2. Art, 1-Macht

Kontingenztafel

9.1.1 Andere Sichtweise

Zudem gibt es noch eine andere Sichtweise. In dieser hat man zwei Kurven, die sich zum Teil überschneiden. Eine steht für die Nullhypothese und eine für die Alternativhypothese. In der Mitte zwischen den beiden Kurven gibt es eine sogenannte Sensitivitätsgrenze. Die Fläche die jeweils auf der andere Seite der Grenze liegt, steht für die Wahrscheinlichkeit, dass die jeweilige Hypothese zu Unrecht verworfen wird.

9.1.2 Kalibrierte Sprache

üblich:

$\alpha = 0.1$	Si=90%	„signifikant“
$\alpha = 0.05$	Si=95%	„sehr signifikant“
$\alpha = 0.01$	Si=99%	„hoch signifikant“

Kalibrierte Sprache

9.2 Spezialfall Gaußverteilung

- bei multivariaten Gaußverteilungen wird $\frac{1}{\sigma^2}$ der univariaten Verteilung im Exponenten durch eine quadratische Form ersetzt
- Äquipotential-Linien sind daher Ellipsen
- Die Ränder des Verträglichkeitsbereichs bei einem Hypothesentest werden daher natürlicherweise entlang dieser Äquipotential-Linien gewählt

9.3 Zum Münzwurf

- Binomialesperiment im entfernten Sinne
- immer das Gleiche zu erhalten, entspricht einer extremen Möglichkeit innerhalb der Binomialverteilung - die Beobachtung liegt in einem der Ausläufer der Verteilung
- so entstehen Zweifel, ob die Stichprobe (Bsp. siehe Folien) wirklich einem Binomialesperiment mit Trefferwahrscheinlichkeit von $\frac{1}{2}$ entstammt
- eine Statistik projiziert Daten geeignet auf eine eindimensionale Koordinate, in der das Interessante geschieht

9.4 Zwei Testverfahren

größte Abweichung zwischen realer Verteilung und vermuteter Verteilung

9.4.1 Kolmogorov-Smirnow-Test

- Sei $F_n(x)$ die empirische kumulierte Verteilung einer Stichprobe mit Umfang n , $\Phi(x)$ die vermutete Verteilung der Grundgesamtheit
- sei $d_n := \sup_x |F_n(x) - \Phi(x)|$ der maximale Fehler, der sich aus beiden ergibt
- Dann wird $\Phi(x)$ mit der Irrtumswahrscheinlichkeit α als kumulierte Verteilung abgelehnt, falls $\sqrt{n} \cdot d_n > \lambda_\alpha$, wobei sich λ_α als Lösung der Gleichung $Q(\lambda_\alpha) = 1 - \alpha$ ergibt. Diese Lösungen liegen in Tabellenform vor.

Wann ist der Test nicht anwendbar?

- kann nur für große Anzahl n von Messwerten benutzt werden. Sonst darf man nicht parameterabhängige Verteilungsfunktionen Φ benutzen, deren Parameterwerte aufgrund des Materials geschätzt werden. Deshalb verwendet man z.B. für Normalverteilungen den χ^2 -Test

9.4.2 χ^2 -Test [für Normalverteilungen]

- Annahme: Eine iid Stichprobe von Klassen, für die man eine theoretische Verteilung besitzt
- getestet wird, ob die Verteilung der Stichprobe der der theoretischen Verteilung entspricht
- Verteilungen der χ^2 Verteilungen, fallen alle gegen ∞ ab

> Vert.-typ darf man vermuten, absolutes bild der Verteilung nicht relevant

> oft test ob es gauß-vert. ist (breite egal)

> chance

$$\chi^2\text{-Verteilung: } f_{\chi^2} = \frac{1}{2^{\frac{N}{2}} \Gamma(\frac{N}{2})} \cdot x^{\frac{N}{2}-1} \cdot e^{-\frac{x}{2}}$$

Eine Beschreibung aus TTM, 1070-1072

6.3.4.2. Das Histogramm

Histogramme entsprechen empirischen Wahrscheinlichkeitsdichten.

Definition: Gegeben seien die Meßwerte

$$x_1, \dots, x_n.$$

Wir wählen Zahlen $a_1 < a_2 < \dots < a_k$ mit den zugehörigen Intervallen $\Delta_r := [a_r, a_{r+1}]$, so daß jeder Meßwert in mindestens einem dieser Intervalle liegt. Die Größe

$$m_r := \text{Anzahl der Meßwerte im Intervall } \Delta_r$$

heißt Häufigkeit der r -ten Klasse. Die empirische Verteilungsfunktion wird durch

$$\varphi_n(x) := \frac{m_r}{n} \quad \text{für alle } x \in \Delta_r$$

definiert. Ihre graphische Darstellung heißt Histogramm.

> chance, dass bin treffer
abkürzt muss für jeden
bin gleich sein
↳ dann am
aussagekräftigsten

> Einkläung bins vorher,
sonst biased opinion

Tabelle 6.8

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
1	1,2	2,1	2,2	2,3	2,3	2,8	2,9	3,0	4,9

Tabelle 6.9

r	Δ_r	m_r	$\frac{m_r}{n}$ ($n = 10$)
1	$1 \leq x < 2$	2	$\frac{2}{10}$
2	$2 \leq x < 3$	6	$\frac{6}{10}$
3	$3 \leq x < 5$	2	$\frac{2}{10}$

Beispiel: Liegen die Meßwerte $x_1, \dots, x_{10}$ wie in Tabelle 6.8 vor, dann liefert Tab. 6.9 eine mögliche Klasseneinteilung der Meßwerte, und das Histogramm ist in Abb. 6.18 dargestellt.




Abb. 6.18

Dazu: Klasseneinteilung muss den gesamten Wertebereich der Zufallsgröße abdecken. Bei einer Verteilung die nach beiden Seiten unbegrenzt ist, müssen die Klassen daher $(-\infty, \infty)$ abdecken. Welche Daten tatsächlich erhoben wurden, ist für den Gesamt-Bereich, den die Klassen abdecken, dagegen unerheblich.

Der χ^2 Anpassungstest erlaubt es festzustellen, ob eine Funktion Φ die Verteilungsfunktion einer zufälligen Größe X ist.

Beispiel:

1. wir wissen alles

Hypothese: X besitzt die Verteilungsfunktion Φ .

Meßreihe: (i) Wir messen die Werte $x_1, \dots, x_n$ von X und nehmen eine Einteilung der Meßwerte in Klassen $\Delta_r := [a_r, a_{r+1}[$ vor mit $r = 1, \dots, k$.
(ii) Wir bestimmen die Anzahl m_r der Meßwerte in dem Intervall Δ_r .
(iii) Wir setzen $p_r := \Phi(a_{r+1}) - \Phi(a_r)$ und berechnen die Testgröße

$$c^2 = \sum_{r=1}^k \frac{(m_r - np_r)^2}{np_r}$$
richtige Meßzahl erwartet: kumulierte W. Vermutung: Zahl der Versuche mal Wahrs. exakte Ws.
(iv) Wir geben uns die Irrtumswahrscheinlichkeit α vor und bestimmen den Wert χ_α^2 aus 0.4.6.4. mit $m = k - 1$ Freiheitsgraden.

Statistische Aussage: Gilt $c^2 > \chi_\alpha^2$, dann ist Φ mit der Irrtumswahrscheinlichkeit α nicht die Verteilungsfunktion von X .
Im Fall $c^2 \leq \chi_\alpha^2$ kann man mit der Irrtumswahrscheinlichkeit α annehmen, daß Φ die Verteilungsfunktion von X ist.

Begründung: Für $n \rightarrow \infty$ genügt die Testgröße c^2 einer χ^2 -Verteilung mit $m = k - 1$ Freiheitsgraden.

Vermutung u. Realität checken

Ziel: soll möglichst klein werden
↳ wenn Fehler zu groß
verwerfen

1. Fehler 1. Art, 2. Freiheitsgrade, 3. Bin. Zahl (nicht Messungen)

9.5 Erweiterung des Tests auf parametrische Verteilungen

- Prüfen: Entsprechen die Daten einer Gaußverteilung
- man vermutet also nicht die Verteilung an sich, sondern nur den Verteilungstyp (z.B. Gauß)
- Verteilung hängt dann noch von unbekannten Parametern ab
- Daten werden dann nicht nur zum Testen, sondern auch zum Schätzen der unbekannten Parameter herangezogen

χ^2 -Test für parameterabhängige Verteilungen: Hängt die Verteilungsfunktion Φ noch von Parametern $\beta_1, \dots, \beta_s$ ab, dann müssen diese aufgrund des Beobachtungsmaterials geschätzt werden.

Bei k Klassen für die Meßwerte muß man dann bei der Bestimmung von χ_α^2 in 0.4.6.4. mit $m = k - 1 - s$ arbeiten.

Beispiel: Mittelwert und Streuung einer Normalverteilung können durch den empirischen Mittelwert $\bar{x}$ und die empirische Streuung Δx geschätzt werden (vgl. 6.3.4.4.).

Im allgemeinen Fall kann man die Maximum-Likelihood-Methode zur Parameterschätzung verwenden (vgl. 6.3.5.).

s steht hier für die Anzahl der unbekannten Parameter. Bei einer Gauß-Verteilung ist s also gleich 2.

- > unbekannte Parameter bestimmen oder schätzen
- > hier erlaubt → deswegen -2: Daten erschöpft
- > Daten nicht mehr so aussagekräftig

Testet man auf 'Gaußverteilung', über die sonst nichts bekannt ist:

$$m = k - 3$$

6.3.4.4. Der χ^2 -Anpassungstest für Normalverteilungen

In der Praxis nimmt man sehr häufig an, daß eine zufällige Größe X normalverteilt ist. Diese Tatsache kann man in folgender Weise testen.

(i) Wir messen die Werte $x_1, \dots, x_n$ von X und bestimmen den empirischen Mittelwert $\bar{x}$ und die empirische Streuung Δx :

$$\bar{x} = \frac{1}{n} \sum_{j=1}^n x_j, \quad (\Delta x)^2 = \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})^2.$$

(ii) Wir geben uns Werte $a_1 < a_2 < \dots < a_k$ vor und bestimmen die Anzahl m_r der Meßwerte, die der Ungleichung $a_r \leq x_j < a_{r+1}$ genügen.

(iii) Mit Hilfe von Tab. 0.34 berechnen wir

$$p_r := \Phi\left(\frac{a_{r+1} - \bar{x}}{\Delta x}\right) - \Phi\left(\frac{a_r - \bar{x}}{\Delta x}\right).$$

(iv) Wir bilden die Testgröße

$$c^2 = \sum_{r=1}^k \frac{(m_r - np_r)^2}{np_r}.$$

(v) Zu vorgegebener Irrtumswahrscheinlichkeit α bestimmen wir mit Hilfe von 0.4.6.4. für $m = k - 3$ Freiheitsgrade die Zahl χ_α^2 .

Gilt $c^2 \leq \chi_\alpha^2$, dann können wir mit der Irrtumswahrscheinlichkeit α akzeptieren, dass X normalverteilt ist. Wenn das Gegenteil gilt, müssen wir mit der Irrtumswahrscheinlichkeit α ablehnen, dass X normalverteilt ist. Es muss darauf geachtet werden, dass $np_r \geq 5$ gilt. Das lässt sich stets durch eine geeignete Wahl der Größen a_r erreichen.

- Es geht um einen einseitigen Test, weil möglichst kleine c -Werte erwünscht sind (gute Übereinstimmung von Daten und Vermutung)
- würden Histogramm und zu prüfende Verteilung perfekt übereinstimmen gälte $c = 0$

Die Meßfehler eines Geräts: Wir betrachten eine Apparatur, die eine Größe mißt (z.B. die Länge eines Gegenstands). Wir wollen nachweisen, daß die Meßfehler normalverteilt sind. Zu diesem Zweck messen wir 100 mal einen geeichten Gegenstand und tragen die Meßfehler x in Tabelle 6.10 ein (z.B. in Mikrometer). Dabei sei $\bar{x} = 1$ und $\Delta x = 10$. Beispielsweise erhalten wir dann

$$p_8 = \Phi\left(\frac{15 - \bar{x}}{\Delta x}\right) - \Phi\left(\frac{10 - \bar{x}}{\Delta x}\right) = \Phi_0(1,4) - \Phi_0(0,9) = 0,42 - 0,32 = 0,10$$

nach Tab. 0.34. Wählen wir die Irrtumswahrscheinlichkeit $\alpha = 0,05$, dann ergibt 0.4.6.4. für $m = 10 - 3 = 7$ Freiheitsgrade den Wert $\chi_\alpha^2 = 14,1$. Wegen $c^2 < 14,1$ können wir mit der Irrtumswahrscheinlichkeit 0,05 annehmen, daß die Meßfehler des Geräts normalverteilt sind.

Streng genommen ist die Bedingung $np \geq 5$ in Tab. 6.10 nicht immer erfüllt. Um das zu erreichen, müssen wir die Gruppen $r = 1, 2, 3$ sowie $r = 9, 10$ zusammenfassen.

9.6 Gültigkeitsvoraussetzungen

Eine summarische Größe, die die Abweichung von der **Nullhypothese** bewertet, ist die **Teststatistik**

$$V = \sum_{j=1}^k \frac{(H_j - n \cdot p_j)^2}{n \cdot p_j}$$

Bei Gültigkeit der **Nullhypothese** ist die **Teststatistik** V **approximativ Chi-Quadrat-verteilt** mit $f = k - m - 1$ **Freiheitsgraden**. Dies gilt unabhängig davon, welche **Verteilung** unter H_0 angenommen wurde.

Approximationsvoraussetzungen:

Die **Approximation** an die **Chi-Quadrat-Verteilung** ist hinreichend, wenn

- $n \cdot p_j \geq 1$ für alle j und
- $n \cdot p_j \geq 5$ für mindestens 80% der erwarteten **absoluten Häufigkeiten**

gilt.

Sind diese Bedingungen nicht erfüllt, müssen vor der Anwendung des **Tests** benachbarte Werte bzw. **Klassen** zusammengefasst werden.

Sind diese Bedingungen nicht erfüllt, müssen vor der Anwendung des **Tests** benachbarte Werte bzw. **Klassen** zusammengefasst werden.

Da die p_j ($j = 1, \dots, k$) unter H_0 vorgegeben sind, folgt außerdem aus den **Approximationsvoraussetzungen**, dass die **Approximation** um so besser ist, je größer der **Stichprobenumfang** n ist.

Bei der Bestimmung der Anzahl der **Freiheitsgrade** ist zu berücksichtigen, dass:

- k die Anzahl der verbliebenen Werte bzw. **Klassen** nach einer eventuell notwendigen Zusammenfassung ist,
- m die Anzahl der unbekannten und aus der **Stichprobe** zu schätzenden **Parameter** der hypothetischen **Verteilung** bezeichnet (wenn unter H_0 eine vollständig spezifizierte **Verteilung** vorgegeben wurde, ist $m = 0$).

. Warnung

- Anzahl Freiheitsgrade oft $\phi = k - 1$
↳ sinnvoller: Anzahl freier Parameter der jeweiligen Verteilung berücksichtigen
- Bei Vorzeichenhäufungen: Gefahr von Fehlents. hinsichtl. Verteilungstyp
- Anfällig gegenüber relativ unwichtigen Verteil.-Abw. im Bereich geringer Häufigkeiten
↳ Fehlents. hinsichtlich zu schlechter Anpassung (Annehmen v. H_1 statt H_0)

Noch mind. 1 anderen Test

10 Ist die Zeitreihe unkorreliert?

Dazu:

$$d = \frac{\sum_{t=1}^{T-1} (\mathbf{X}'_{t+1} - \mathbf{X}'_t)^2}{\sum_{t=1}^T (\mathbf{X}'_t)^2}$$

- Perfekte zeitliche Korrelation: $d = 0$
- Zeitlich unkorreliert: $d = 2$
- Perfekte zeitliche Anti-Korrelation: $d = 4$
- Auswertung verwickelt (siehe SZ, DSW).
 - Automatisierte Routinen standardmäßig vorhanden.
- Standardtest, um Residuen bei linearer Regression zu prüfen.
 - Zahl der Prediktoren angeben. Ohne weitere Spezifizierung: $\# = 1$.

Erweiterung ja/nein Frage: Programm gibt an wie weit draußer man ist
 ↳ kleiner p-Wert: extrem weit draußer

11 Der p-Wert

Nachtrag zum Hypothesentest:

- Anstelle zu fragen, ob eine Hypothese verworfen werden muss bei einer vorgegebenen Signifikanz = 1- Fehler 1. Ordnung, kann man auch fragen bei welchem Fehler 1. Ordnung gerade der Übergang zwischen verwerfen und nicht verwerfen stattfindet.
- ist informativer als ja/nein als Charakteristikum von Daten, weil dies dann nützlicher für verschiedene Anwendungen, die mit unterschiedlichen Signifikanzniveaus einhergehen können, sein würde



BSP $\alpha = 2\%$, bei Niveau 95% : H_0 verwerfen
 bei Niveau 99% : H_0 nicht verwerfen

12 Lineare Regression

- wir setzen die Messpunkte mit dem 'Ideal' (der Modellgeraden) über Residuums-Terme ϵ_i in Verbindung:

$$y_i = ax_i + b + \epsilon_i \quad \text{Korrekions-/Abweichungs-/Rauschterm} \quad (12.1)$$

- ein derartiges Vorgehen ist grundsätzlich immer nötig, weil man die Differenz zwischen Daten und Modell erklären muss. Ohne eine solche Erklärung kann man formal nicht weiterarbeiten.
- dies bedeutet, dass man, um Modell und Daten in Beziehung setzen zu können, immer ein 'Meta-Modell' definieren muss, das den unerklärten Rest auffängt.

Warum Gerade?

- > automatisiert was ablesen
- > dann gerade praktisch
- > Computer hat was kontinuierl. zum ablesen
- > vorläuf. Modell für zsmhang v. x und y
- > kontinuierliches y: viele Modellierung Klima-Ökosystem

- 26 wenn $x \rightarrow$ Zeitschritte:
- Dann Zukunftsvorhersage
 - Trends werden deutlich

12.1 Methode der kleinsten Quadrate

- schlägt vor, die Gerade so zu wählen, dass die Summe der Quadrate der Residuen minimiert wird:

$$(\hat{a}, \hat{b}) := \underset{(a,b)}{\operatorname{ArgMin}} \sum_{i=1}^n \epsilon_i^2(a, b) \quad (12.2)$$

mit $\sum_{i=1}^n \epsilon_i^2(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2$

- technisch finden wir besagtes Minimum, durch die notwendige Bedingung:

$$\frac{\partial}{\partial a} \sum_{i=1}^n \epsilon_i^2(a, b) = 0 \quad (12.3)$$

$$\frac{\partial}{\partial b} \sum_{i=1}^n \epsilon_i^2(a, b) = 0 \quad (12.4)$$

12.2 Schätzer

- Schätzen der Parameter a und b :

$$\hat{a} = \frac{\sum_i x_i y_i - \frac{1}{n} \sum_i x_i \sum_i y_i}{\sum_i x_i^2 - \frac{1}{n} (\sum_i x_i)^2} \quad \begin{array}{l} \text{Reduktion Abweichung} \\ \text{in y-Achse:} \\ \text{Methode der kleinsten Quadrate} \end{array} \quad (12.5)$$

$$\hat{b} = \frac{\sum_i y_i}{n} - \hat{a} \frac{\sum_i x_i}{n} \quad (12.6)$$

12.3 Interpretation

- Wenn ϵ_i identisch und unabhängig aus einer Gaußverteilung gezogen sind, ergeben sich folgende Folgerungen:
- Die auf der vorherigen Folie angegebenen Schätzer sind Maximum Likelihood Schätzer
- Man kann über Reihe von Hilfsgrößen exakte Konfidenzintervalle konstruieren

12.4 Konfidenzintervall für Steigung

- dazu: geschätzte Standardabweichung der Residuen:

$$\hat{\sigma}_\epsilon := \sqrt{\frac{\sum_{i=1}^n (y_i - (\hat{a}x_i + \hat{b}))^2}{n-2}} \quad (12.7)$$

- das $(n-1)$ -Fache des Schätzers der Varianz von x :

$$s_{xx} := \sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2 \quad \begin{array}{l} \text{In Python: student-t-Verf.} \\ \hookrightarrow 95\%: \text{ auf beiden Seiten} \\ \quad 2.5\% \text{ !} \\ \hookrightarrow \text{Steuerung der x-Werte} \end{array} \quad (12.8)$$

- $[\hat{a} - \frac{t_{1-p, n-2} \hat{\sigma}_\epsilon}{\sqrt{s_{xx}}}, \hat{a} + \frac{t_{1-p, n-2} \hat{\sigma}_\epsilon}{\sqrt{s_{xx}}}]$ ist dann p -Konfidenzintervall von $\hat{a}$.

12.5 Konfidenzintervall für Vorhersage

- möchte man das lineare Modell nutzen, um zu beantworten welche Realisation von Y eintritt, wenn $X = x$ eingetreten ist, benötigt man zuerst einen Schätzer: $\hat{y} = \hat{a}x + \hat{b}$
- zunächst setzen wir die Abkürzung für das arithmetische Mittel:

Nahel am Mittelwert:
Fehlerbalken am geringsten
immer weiter weg → größerer Fehler

$$\hat{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \text{Breite kleiner: Fehlerbalken kleiner} \quad (12.9)$$

- möchte man durch das Konfidenzintervall auch noch den Rauschterm σ_ϵ mit ausdrücken, durch den y von der Vorhersagegeraden abweichen wird, ergibt sich:

$$\left[\hat{y} - t_{1-p, n-2} \hat{\sigma}_\epsilon \sqrt{1 + \frac{1}{n} + \frac{(x - \hat{x})^2}{s_{xx}}}, \hat{y} + t_{1-p, n-2} \hat{\sigma}_\epsilon \sqrt{1 + \frac{1}{n} + \frac{(x - \hat{x})^2}{s_{xx}}} \right] \quad (12.10)$$

p-Konfidenzintervall von der Vorhersage. 1 ist dabei der Abstand von der geschätzten Geraden, $\frac{1}{n}$ ist Positionsfehler der geschätzten Geraden, der dritte Term ist Steigungsfehler der geschätzten Geraden.

12.6 Interpretation des Intervalls

Je mehr sich ihr Prediktor x aus der Standardabweichung von x entfernt, desto unsicherer wird ihre Vorhersage.

13 Der Korrelationskoeffizient

Korrelation heißt nicht Kausalität! Wenn beispielsweise ein dritter Prozess die beiden Zeitreihen beeinflusst, dann haben die beiden Prozess eventuell nichts miteinander zu tun.

konkrete Formel: Wie gut ist y aus x vorhersagbar? Wie gut haben die beiden miteinander zu tun?

13.1 Umgang mit multivariaten Verteilungen

- Zwei Zufallsgrößen X, Y seien durch eine gemeinsame Wahrscheinlichkeitsdichteverteilung $p(x, y)$ charakterisiert joint distribution
- dann erweist es sich als hilfreich, die zugehörigen Marginalverteilungen zu definieren:

$$p_x(x) := \int p(x, y) dy, p_y(y) := \int p(x, y) dx \quad (13.1)$$

- Mittelwert EX und Standardabweichung ΔX von X werden dann wie im invariante Fall definiert und zwar über $p_x(x)$. Analoges gilt für Y .

13.2 Kovarianz und Korrelationskoeffizient

- Kovarianz $\text{Cov}(X, Y) := \int (x - EX)(y - EY)p(x, y) dx dy$
- Erinnerung: $\text{Var}(X) = \int (x - EX)(x - EX)p(x) dx$

Wenn nur auf x fixieren: 1D Berechnung
einfachere Verteilung
aus allg. Verteilung y weg integrieren
Dann Standardabw., Mittelwert berechenbar

Gut: große, positive Zahlen

Varianz: Zweites zentrales Moment

$r = -1$: perfekt antikorreliert $\triangleright$

$r = 1$: perfekt korreliert $\triangleleft$

$r = 0$: keine Korrelation keine

→ haben nichts miteinander zu tun

- Die Antwort dazu, ob X und Y stark oder schwach voneinander abhängen, ergibt sich aus dem Wert des **Korrelationskoeffizienten**:

$$r := \frac{\text{Cov}(X, Y)}{\Delta X \Delta Y} \quad (13.2)$$

r^2 niemals unter 50%

- man kann zeigen: $r \in [-1, 1]$, je größer $|r|$, desto stärker sind X und Y voneinander abhängig.

→ aber nie Linearität direkt als Wahrheit verkauften
↳ nur Annäherung
↳ KEINE VORHERSAGE

13.3 Multivariate Gaußsche Dichte-Verteilung

- $\mu = (\mu_1, \dots, \mu_p)$ und Σ positiv definite $(p \times p)$ -Matrix, dann heißt $N_p(\mu, \Sigma)$ p-variate Normalverteilung, wenn die Dichte lautet: $f(x/\mu, \Sigma) = \frac{1}{(2\pi)^{p/2} (\det \Sigma)^{1/2}} e^{-(x-\mu)^T \Sigma^{-1} (x-\mu)/2}$

13.4 Interpretation Korrelationskoeffizient

- Lösung zu Minimierungsproblem der Methode der kleinsten Quadrate: $\text{ArgMin}_{(a,b)} E(Y - aX - b)^2$ ist die sogenannte Regressionsgerade mit $EY + r \frac{\Delta Y}{\Delta X} (X - EX)$, je größer r , desto stärker bewegt sich Y mit X
- für mittleren quadratischen Fehler der Regressionsgerade gilt: $E(Y - aX - b)^2 = (\Delta Y)^2 (1 - r^2)$
- daraus kann man folgern, dass je größer r desto besser der Fit, wenn $r = 1$, ist der Fit perfekt, wenn $r = 0$, ist der Fit am schlechtesten

13.5 Erklärte Varianz

Wichtig für Angabe v. Qualität des Modells
Formalität: Aufspaltung von y^2 (Anteil erklärter Varianz in y)

Zu $E(Y - aX - b)^2 = (\Delta Y)^2 (1 - r^2)$

- oft ist es besser sich nicht nur die geschätzte Korrelation, sondern auch den Anteil der erklärten Varianz anzuschauen: r^2
- 'erklärte Varianz von y durch x ', weil sich die Varianz zerlegen lässt nach: $(\Delta Y)^2 = r^2 (\Delta Y)^2 + (1 - r^2) (\Delta Y)^2 = \text{erklärte Varianz} + \text{mittlerer quadratischer Fehler der Regressionsgeraden}$
Gesamt-Schwankung
- Folgerung: weitere Faktoren die manipulieren
- r^2 -Anteil der Schwankung von y die sich durch x erklären lassen

13.6 Invarianz unter affinen Transformationen

Wenn $p(x, y)$ eine zweidimensionale Dichte beschreibt und zu einem Korrelationskoeffizienten r zwischen x, y führt, dann sind $x' := ax + b$ und $y' := cy + d$ ebenfalls mit r korreliert.

13.7 Schätzung des Korrelationskoeffizienten


Schätzung für wahre Korrelation

- Schätzen der univariaten ersten und zweiten Momente: $\hat{EX} = \frac{1}{n} \sum_{i=1}^n x_i$, $\hat{EY} = \frac{1}{n} \sum_{i=1}^n y_i$,
 $\hat{\Delta X} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{EX})^2}$, $\hat{\Delta Y} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \hat{EY})^2}$
- Schätzung des Korrelationskoeffizienten: $\hat{r} = \frac{1}{(n-1) \hat{\Delta X} \hat{\Delta Y}} \sum_{i=1}^n (x_i - \hat{EX})(y_i - \hat{EY})$

↑
Abw. in x u. y

arithm. Mittel:
• Schätzer Erwartungsw. von x u. y
• Erweiterte Notation

Beispiele zum Umgang mit korrelierten Daten



Lineare Regression: allg. Vorgehen

STATISTISCH

1. Datensatz (x, y) -> Plotten (zB als Punktwolke)
 - a. Linearer Zusammenhang?
 - b. Nicht Linear? -> exponentiell, ...
 - c. Sehen wir ein Phänomen? (oder zwei datensätze in einem Plot)
2. Berechnen! $Y = ax + b$ -> Plotten
3. Daraus bestimmen:
 - a. Fehlerbalken/Konfidenzintervalle
 - b. Residuen/ R^2
 - i. Wie wahrscheinlich ist der Zusammenhang linear?
 - ii. Wie wahrscheinlich kommen die Punkte aus demselben normalverteilten Datensatz?
 - c. P-Wert (Signifikanzniveau)

Ab jetzt Reihenfolge beliebig

PROZESSE

tests: χ^2 ,
durbin watson

4. (Physikalische) Interpretation
 - a. Kann beliebig Komplex werden (zB. numerische Modellstudie, Anwendung von Theorie)
 - b. Ausreißer? Messfehler?
5. Evtl. Anwendung des linearen Modells auf Vorhersagen
6. Limits diskutieren

13.8 Konfidenzintervall für Korrelationskoeffizienten

- Näherung für große n für p -Konfidenzintervall: $z := \frac{1}{2} \ln \left(\frac{1+\hat{r}}{1-\hat{r}} \right)$, $\delta z := \frac{\frac{z_1+p}{2}}{\sqrt{n-3}}$, hier ist $Z_{(.)}$ das p -Quantil der Standardnormalverteilung
- $[\tanh(z - \delta z), \tanh(z + \delta z)]$ ist dann ein näherungsweise p -Konfidenzintervall für r

Sonst immer bootstrapping bei nicht exakter Formel

↳ Näherungsformel: einfach einprogrammieren
↳ Logarithmus, standard norm. Vert.

13.9 Einige Merkgeln

- Vor einer Regression sollte geprüft werden, ob überhaupt ein **linearer Zusammenhang** vorliegt. Hierzu können das Anschauen der Streudiagramme, aber auch das Berechnen des **Korrelationskoeffizienten** eine Hilfe darstellen.
- Wenn möglich sollte durch Prozesswissen geprüft werden, ob der Korrelationskoeffizient durch weitere Größen jenseits der beiden Betrachteten beeinflusst werden kann. Dann müsste das statistische Modell erweitert werden.
- Sind die Datenpaare unabhängig aus derselben Grundgesamtheit gezogen oder sind sie womöglich entlang der Achse korreliert? Falls letzteres zutrifft, müssten aufwendigere Verfahren der Zeitreihenanalyse in Anschlag gebracht werden.

Dazu: ein großes r sagt nichts über die Qualität der Linearitäts-Annahme aus.

Eine lineare Regression kann auch bei 'kleiner' Korrelation angemessen sein.

Heteroskedastie: Die Annahme konstanter Varianz wird verletzt. Wenn überhaupt gaußverteilt, dann ändert sich die Verteilung ständig, es liegt kein stationärer Prozess vor, vorher könnte man eventuell Bootstrapping durchführen. [Sta. Abw. des Rauschen nicht konst., verändert sich laufend]

13.10 Methode der kleinsten Quadrate nicht robust gegen Ausreißer

Wir haben dann: $Y = \dots + \dots x + \text{noise} + \text{outliers}$

Ein Ausreißer beeinflusst das Ergebnis proportional zu seiner Größe. Dies ist anders beim Median.

13.11 Vorteile der Methode der kleinsten Quadrate

man findet sie überall

- Wenn die Residuen aus einer stationären Zeitreihe stammen, liefert die Methode der kleinsten Quadrate asymptotisch den besten (im Sinne von min. Varianz) linearen unverzerrten Schätzer der Regressionsparameter
- = 'BLUE Estimator' ('best linear unbiased estimator') (bezieht sich auf Varianz)

14 Bootstrapping von linearer Regression

14.1 Bootstrapping

- Strategie: Wir resampeln den Messvektor
 - Ziehen mit Zurücklegen
 - Länge des neuen Messvektors genauso lang wie der alte

- Auf dem resampten Messvektor berechnen wir unsere Statistik
- Wir führen es n_{boot} mal durch ($n_{boot} > 1000$)

14.2 Bootstrapping von linearer Regression

- Lineare Regression basiert auf der Abhängigkeit der Werte
- Daher: Ziehen einzelner Tupel anstatt X - und Y - Werte getrennt

15 Multivariate lineare Regression

8.4.1 The Multiple Regression Model. A multiple linear regression model expresses a response variable as an error term plus a mean that is conditional upon several factors. Suppose we observe a response variable Y and k factors denoted by $X_1, \dots, X_k$ that are thought to affect the expected value of Y . These random variables are all observed n times. The result is a sample of n $(k + 1)$ -tuples represented by random variables $(Y_i, X_{1,i}, \dots, X_{k,i})$ whose actual observed, or realized, values are represented by $(y_i, x_{1,i}, \dots, x_{k,i})$, for $i = 1, \dots, n$. The multivariate version of (8.10) is given by

$$Y_i = a_0 + \sum_{l=1}^k a_l x_{li} + E_i, \quad (8.31)$$

Dürfen beliebig verteilt sein.

Müssen im Kontext dieser Theorie gaußverteilt sein.


Muss keine Gauß-Verteilung sein

Erklären v. x u. y
immer Wertpaare

Bsp:
 y : temp, x : Agenten wie CO₂, Methan, Schwefel

↳ für jedes x Vorfaktor a

Bestimmung Ebene



$x_1 Y$ wird jetzt durch verschiedene Variablen vorhergesagt (k -verschiedene x -Werte). Die E_i 's müssen dabei normalverteilt sein (sind iid Variablen mit Mittelwert 0, iid=Unabhängig und identisch verteilte Zufallsvariable), während die x_i 's beliebig verteilt sein können.

- dies ermöglicht auch die Darstellung von Fits höherer Ordnung [Koeff. linear (Formal)]
- Beispiel: $Y_i = a_0 + a_1 x_i + a_2 x_i^2 + E_i$
- Lineare Regression bezieht dabei auf das lineare Auftreten der zu fittenden Koeffizienten (a_i 's), die x_i 's müssen daher nicht linear sein)

15.1 Design-Matrix-Formulierung

- Designmatrix X ist $n \times (k+1)$ Matrix, mit erster Spalte komplett konstant 1, die Indizes der $x_{i,j}$ gehen von $i = 1, k$ und $j = 1, n$, dabei sind k die Prediktoren und n die Beobachtungen
- $\vec{a}$ ist dann ein $k + 1$ dimensionaler Vektor

$$X = \begin{pmatrix} 1 & x_{1,1} & \dots & x_{k,1} \\ 1 & x_{1,2} & \dots & x_{k,2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \dots & x_{k,n} \end{pmatrix}$$

31


k = Prediktoren
 n = Beobachtungen

Ansreißer sehr deutl.
Bei Messfehler rausnehmen

wir haben dann $Y = X\vec{a} + \vec{E}$

15.1.1 Schätzer für das multivariat-lineare Modell

- $\hat{\vec{a}} = (X^T X)^{-1} X^T \vec{Y}$, ($\vec{Y}$ ist dabei der Datenvektor)
- Dieser Schätzer ist erwartungstreu



15.1.2 Wie viel der Varianz in Y wird dadurch geklärt?

- wie im univariaten Fall setzt man $R^2 = \frac{SSR}{SST}$
- $SSR := \sum_{i=1}^n (\hat{a}_0 + \sum_{l=1}^k \hat{a}_l x_{li} - \hat{y})^2$ (d.h. den (skalierten) Varianzanteil in Y , der aus dem Vorhersagemodell stammt, entlang der Datenreihe)
- $SST := \sum_{i=1}^n (y_i - \hat{y})^2$ (d.h. die gesamte (skalierte) Varianz in Y)
- R^2 fragt also nach wie vor: Welchen Anteil der Varianz in Y kann ich mit Hilfe des Fit-Modells erklären? (je besser das Modell, desto kleiner die Residuen)
- eine Art verallgemeinerter Varianz der auf die interessierenden Koeffizienten reduzierten Design-Matrix:

$$U = [U^T (X^T X)^{-1} U]^{-1/2}$$

Reduktionsmatrix:
↳ Koeffiz. aber nicht alle
↳ Nur wichtige Parameter

↳ Statist. in Genauigkeit erhöhen (15.1)

U ist dabei eine Reduktionsmatrix, sollten wir nicht an allen Prediktoren interessiert sein

- die Summe der quadratischen Residuen ergibt sich dann als:

$$SSE = \vec{Y}^T (I - X(X^T X)^{-1} X^T) \vec{Y} \quad (15.2)$$

I ist dabei eine $n \times n$ Identitätsmatrix.

15.1.3 Schätzung der Varianz der Residuen

$\hat{\sigma}_E^2 = \frac{SSE}{df_E}$, mit df als Anzahl der Freiheitsgrade. Die Schätzung ist unbiased. df_E ist dabei $n - k - 1$.

15.2 F-Verteilung

wenn wir mehrere Parameter gleichzeitig wollen: p ist dabei die Anzahl der gleichzeitig zu bestimmenden Parameter:

Thus the $\tilde{p} \times 100\%$ confidence region, an ellipsoid, is composed of all points in the $(k+1)$ -dimensional parameter space that satisfy the inequality

$$\frac{(\hat{\vec{a}}^s - \vec{a}^s)^T V^{-1} (\hat{\vec{a}}^s - \vec{a}^s)}{p \hat{\sigma}_E^2} < F_{\tilde{p}}, \quad (8.36)$$

Matrix
Schätzer
Tatsächlicher Wert
Fehler zw. Schätzer und Wirklichkeit

where $F_{\tilde{p}}$ is the $\tilde{p}$ -quantile of the F distribution with (p, df_E) df obtained from Appendix G.

Abbildung 4: F-Verteilung

> symm. Matrix
> $\hat{\vec{a}}$: Schätzer
↳ von Steigung, Achsenabschnitt etc.
o. Taylorreihen
1. Taylorreihen

15.3 Multivariate lineare Regression ohne Offset

- Ohne externes Forcing gibt es auch keine Systemantwort
- könnte beim Fingerprinting eine Rolle spielen, falls man meint, der Bias des eigenen Modells sei bereits korrigiert

15.4 Änderungen gegenüber dem Fall mit Offset a_0

- a_0 weglassen
- Spalte mit $(1, 1, 1, \dots, 1)^T$ in Design-Matrix weglassen
- Dann: Formeln für beste Schätzung des Modells und Konfidenz-Volumen bleiben gleich
- es gibt Ausnahmen:

Source	Sum of Sq.	df
Regression	SSR	$df_R = k$
Error	$SS\mathcal{E}$	$df_E = n - k$
Total	SST	$df_T = n$

15.5 Fingerprinting

- Wie setzt sich das Erwärmungssignal in Raum und Zeit aus Raum-Zeit-Mustern diverser Forcings zusammen? ('Attribution')
- mögliche Forcings: CO_2 und weitere Treibhausgase, SO_2 , Ozon,...
- Relation zur linearen Regression:
 - k =Zahl der unabhängigen Einflüsse (hier $k = 2$)
 - n =Zahl der raum-zeitlichen Komponenten, um das Feld zu bestimmen (hängt hier von der räumlichen Auflösung ab)
 - Allerdings hängt beim Finger-Printing noch die Rausch-Amplitude von der Koordinate $I = 1, \dots, n$ ab und die Rauschterme können korreliert sein

15.6 Detection & Attribution

- Detection: Sind die Beobachtungen verträglich mit der Null-Hypothese, dass alles durch natürliche Variabilität erklärbar sei?
- Attribution: Welche lineare Superposition der Muster diverser Forcings erklärt die Daten am besten? (Lineare Regression)
- Paradigma, das häufig genutzt wird ist, dass eine Änderung im Klima y gesehen wird als lineare Kombination aus äußeren erzwungenen Signalen X und und interner Klimavariabilität u :



$$y = Xa + u \quad \begin{array}{l} \text{Darf korreliertes} \\ \text{Rauschen sein} \end{array} \quad (15.3)$$

- a best linear unbiased estimator of the vector of scaling factors is given by:

$$d = \frac{\sum_{t=1}^{T-1} (x'_{t+1} - x'_t)^2}{\sum_{t=1}^T (x'_t)^2} \quad d = 0: \text{perfekte zeitl. Korrelation} \quad d = 4: \text{perf. zeitl. Anti-Korrel.}$$

$$a = (X^T C^{-1} X)^{-1} X^T C^{-1} y = (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y}. \quad (15.4)$$

Ist die Zeitreihe unkorreliert?
 $d = 2$: zeitlich unkorreliert
 > d klein bei pos. Korrel.
 > d groß bei anti-korrel.
 $0 \leq d \leq 4$
 Gemischter Fall bei 2



Benachbarte Werte stark korreliert
 $\hookrightarrow$ positiv

- $\tilde{X}$ und $\tilde{y}$ repräsentieren die die Signalmuster und Beobachtungen nach der Normalisierung durch die klimatische interne Variabilität
- C ist hier die Kovarianzmatrix der raum-zeitlichen Felder

16 Zeitreihen

- Zeitreihen in den Erdsystem-Wissenschaften: Beobachtungen sich kontinuierlich entwickelnder Systeme entlang der Zeitachse
- Insofern Teil der Statistik, als dass man einen Teil des Systems vereinfachend als stochastischen Prozess darstellt
- Vereinfachend bedeutet nicht, dass dadurch die Behandlung einfach wird
- sie wird lediglich einfacher, als wenn man rein deterministisch-höherdimensional vorgehen würde. (Man kann die Dynamik unterteilen in schnelle und langsame Prozesse)
- Originalsystem: $\frac{dy}{dt} = \mathbf{g}(y) + \mathbf{f}(t)$ ($\mathbf{f}$ für externes Forcing)
- Hierbei stellt y einen hochdimensionalen Vektor dar (in einem GCM: $\dim(y) > 10^8$).
- Manchmal ist man berechtigt, auf Koordinaten zu transformieren, so dass man schnelle Prozesse als Rauschen η darstellen kann ('Skalen-Separation'). So ein Zufallsprozess kann insbesondere im Kontext chaotischer Dynamik der schnellen Variablen berechtigt sein
 - siehe auch Ergodizität: Der dynamische Fluss 'besucht' jede Phasenraumzelle, daher sind Zeit und stoch. Mittel approx. gleich.
- Die Dimension der langsamen Prozesse x soll dann, damit sich die Aktion lohnt, um Größenordnungen kleiner sein als die Original-Dimension.
- Außerdem hofft man, den Rauschterm aus einer allgemeinen Klasse wählen zu können (Gaußsch?), so dass man ihn bis auf ein paar Parameter kennt
- so ist das vereinfachte System:

$$\frac{dx}{dt} = \mathbf{h}(x) + \mathbf{f}_2(t) + \eta(t)$$

Durbin-Watson:
Wie ähnlich sind sich
Nachbarwerte

(16.1)

(für x hat man in der Regel 10 bis 20 Dimensionen, η steht für das Rauschen (schnelle Prozesse, die nicht gut zu interpretieren sind)), leichter zu behandeln - oder zumindest zu verstehen - als das allgemeine.

16.1 Zusammenhang Zeitreihe und Dynamischer Fluss

Originalsystem kann auch noch im Hinblick auf eine Diskretisierung approximiert werden:

$$y_{n+1} \approx y_n + (g(y_n) + f_n)\Delta t \quad (16.2)$$

analog das stochastische Näherungssystem:

$$x_{n+1} \approx x_n(h(x_n) + f_{2n})\Delta t + \sqrt{\Delta t}N_n \quad (16.3)$$

(N für Noise)

Dass im Rauschterm die Wurzel des Zeitschritts auftritt, liegt an der Theorie der Brownschen Bewegung:

- Der mittlere Abstand eines Teilchens unter Rausch-Antreib wächst mit der Wurzel der Zeit, nicht linear mit der Zeit!

16.2 Beobachtungs-Rauschen

$X_t = D_t + N_t$, X_t steht dabei für eine time series, die aus zwei Komponenten besteht: einer dynamisch bestimmten Komponente D_t und einer stochastischen Komponente N_t

Der deterministische und der stochastische Anteil entwickeln sich je unabhängig voneinander.

16.2.1 Gegenbeispiel

- in der Regel fließt bei jedem Zeitschritt die Rausch-Komponente in die dynamische Komponente ein
- Beispiel: **Brownsche Bewegung**

$$x_{n+1} \approx x_n(h(x_n) + f_{2n})\Delta t + \sqrt{\Delta t}N_n \quad (16.4)$$

- Einfachster Fall einer solchen Verquickung - Annahmenliste für AR1-Prozess:
 - Das System ist im Gleichgewicht (d.h. in einem stabilen Fixpunkt der deterministischen Dynamik)
 - h wird durch eine Tayler-Entwicklung erster Ordnung genähert
 - $f = 0$
 - Ohne Beschränkung der Allgemeinheit wird angenommen, dass dieses Gleichgewicht bei $x = 0$ liegt
 - Aus der Gleichgewichtsbedingung ergibt sich dann für den Spezialfall ohne Forcing: $h(0) = 0$:

$$x_{n+1} \approx x_n + \frac{dh}{dx}x_n\Delta t + \sqrt{\Delta t}N_n \quad (16.5)$$

- $\frac{dh}{dx}$ ist dann die quadratische Matrix der partiellen Ableitungen
- ferner wird angenommen, dass N_n **weißes Rauschen** darstellt
 - * weißes Rauschen hat kein Gedächtnis, d.h. der nächste Zeitschritt weiß nicht, was der davor gemacht hat
 - * unendliche Folge von normal verteilten zufälligen Variablen, mit einer Mittelwert von 0, ist das einfachste Beispiel eines stochastischen Prozesses
 - * $x_{n+1} = \sqrt{\Delta t}N_n$

16.3 AR1-Prozess

AR1 steht für:

1 ist bei $n+1$

→ Zukunft hängt mit Gegenwart zusammen

- dazu Übertrag: $x_{n+1} \approx x_n + \frac{dh}{dx}x_n\Delta t + \sqrt{\Delta t}N_n$

- hier: $x_{n+1} = cx_n + z_n$

- im einfachsten Fall stellen c, x Skalare dar

- dann: $|c| < 1$. Dies garantiert Stationarität:

- stochastischer Prozess ist stationär, wenn alle stochastischen Parameter unabhängig von der Zeit sind.
- wenn X_t stationär ist, gilt:
 - * X_t hat für alle t die selbe Verteilungsfunktion


- Weißes Rauschen für $c = 0$

- für $c = 1$ Brownsche Bewegung

> Quadratische Matrix

$n = \text{zeitlich}$
 $t = \text{kontinuierl.}$
 $n = \text{diskret}$

Zusammenfassung zu AR1:

16.3.1 Ansatz 2 für AR1: **Erst Taylor, dann Diskretisierung:**

- exaktes System
- Näherung durch 'viele' deterministische (gewöhnliche) DGL's
- Trennung in schnell und langsam. Schnell vereinfacht als Rauschen dargestellt. Das System kann noch von einem Parameter langsam veränderlichen $f(t)$ abhängen, der ein externes Forcing mit abbildet.

$$\frac{dx}{dt} = h(x, f(t)) + \eta(t) \quad (16.6)$$

- Das System ist im Gleichgewicht (d.h. in einem stabilen Fixpunkt der deterministischen Dynamik)
- h wird durch eine Taylor-Entwicklung erster Ordnung genähert
- kein externes Forcing
- Ohne Beschränkung der Allgemeinheit wird angenommen, dass dieses Gleichgewicht bei $x = 0$ liegt

16.4 Übersicht der Näherungen 3 für AR1

- Übertrag: $\frac{dx}{dt} \approx -A(f)\delta x + \eta(t)$
- In der Praxis schätzt man x_0 , indem man das arithmetische Mittel bildet. Falls $x_0(f(t))$ einen Trend aufweist, muss man einen Trend durch eine Regression schätzen. Dann ist $\delta x = x(t) - x_0(f(t))$
- Falls das System eindimensional ist, vereinfacht sich dies zu: $\frac{dx}{dt} \approx -a(f)\delta x + \eta(t)$ (wie harmonischer Oszillator)

Schätzer
 $\hat{c} = \frac{\langle x_n x_{n+1} \rangle}{\langle x_n^2 \rangle}$
 mit $\text{Var}(\hat{c}) \sim \frac{1}{N} (1-c^2)$
 autocor. mit Zeitschritt 1

$c(\tau) = \frac{1}{T} \sum_{t=1}^T x_t x_{t+\tau}$
 $c = \text{propagator: von heute auf morgen}$
 Schätzformel.
 Je mehr Gedächtnis: größere Differenz

Auto-korrel. AR1
 $\gamma(k) = c^{|k|} \sigma^2 / \Delta t = e^{(\ln c) |k| \Delta t}$
 $\Rightarrow \gamma(\Delta n) = c^{|\Delta n|} = e^{(\ln c) |\Delta n|}$

Bedeutung: Gedächtnis eines AR1-Prozesses zerfällt exponentiell mit der Zeit

- sinkt exponentiell
- $\log(c)$: negative Zahl
- ab klingende exponent v. t
- $c \rightarrow 1$: nicht verschwind. Gedächtnis
 ↳ nur mit Zeitschritten: n



16.5 Übersicht der Näherungen 4

- Übertrag: $\frac{d\delta x}{dt} \approx -a(f)\delta x + \eta(t)$
- Übergang ins Zeit-Diskrete, zunächst deterministisch
- Mit Rauschen: $\delta x(n+1) \approx c\delta x(n) + z(n)$
- Dieses ist der eindimensionale AR1-Prozess mit $|c| < 1$.
- In höheren Dimensionen ist c eine quadratische Matrix.

Covarianz:

- > Was tun die Variablen gemeinsam?
- > Schwingen in dieselbe Richtung?
- > Als heute morgen vorhersagbar?
- > Wie stark gemeinsame Schwankungen?
- Größe der Schwankung der einzelnen Variablen rausrechnen
- Je mehr Zustände kommt: bessere Zukunftsvorhersage

16.6 Übersicht der Näherungen 5

- Übertrag: $\delta x(n+1) \approx c\delta x(n) + z(n)$
- Bemerkung zum Rauschterm: Für jeden Zeitschritt wird der Rauschterm aus derselben Gaußverteilung mit Erwartungswert Null gezogen. Ihre Standardabweichung muss so gewählt werden (falls keine anderen Angaben vorliegen), dass die resultierende Standardabweichung von δx des kontinuierlichen Prozesses reproduziert wird. Es gibt auch Anwendungen, für die eine beliebige Standardabweichung gewählt werden kann.


⇒ Gedächtnis-Eigenschaft

16.6.1 Varianz des 1D-AR1-Prozesses

$$\text{Var}(X) = \frac{\text{Var}(Z)}{1 - c^2} \quad (16.7)$$

Das bedeutet unter anderem, dass für c gegen 1, die Varianz von X gegen unendlich geht. Das System verliert dann den stabilen Bereich.

16.7 Sattelknoten-Bifurkation



Dazu: verliert von unten nach oben gesehen die Stabilitätseigenschaften schrittweise, es ist nicht möglich wieder zum Originalzustand zurückzukehren.


Wir verändern also langsam einen äußeren Parameter und dann verschwindet ein stabiler Zustand. Passiert abrupt. Es gibt immer einen Zwillingszustand, dann aber instabiler Fixpunkt.

- Kann man universelle Indikatoren finden, die anzeigen, dass man sich auf eine Bifurkation zubewegt?

$$\frac{d\delta x}{dt} \approx -a(f)\delta x + \eta(t) \quad (16.8)$$


- An der Bifurkation, die uns hier interessiert, sind folgende Ausdrücke synonym:
 - Potentialkrümmung ($\alpha U''$) $\rightarrow 0$
 - $a \rightarrow 0$ ($\alpha U''$)
 - $c = 1 - a\Delta t \rightarrow 1$, kritischer Moment, wenn AR1 Prozess nicht mehr stabil ist, ist dann Brownsche Bewegung und kein AR Prozess mehr.

Dazu:



<https://de.wikipedia.org/wiki/Sattel-Knoten-Bifurkation>

Frühwarnung an einem komplexen Modell



Held & Kleinen, 2004

17 Wie gelangt man zu einer 1D Zeitreihe?

17.1 Einschub: Wie geht man mit hochdimensionalen Zeitreihen um?

Eine Option: Empirical Orthogonal Functions

17.1.1 Schätzung der Kovarianzmatrix

Schätzung des mean Vektors:

$$\hat{\vec{u}} = \frac{1}{n} \sum_{i=1}^n \vec{X}_i \quad (17.1)$$

Schätzung der Kovarianzmatrix:

$$\hat{C} = \frac{1}{n-1} \sum_{i=1}^n (\vec{X}_i - \hat{\vec{u}})(\vec{X}_i - \hat{\vec{u}})^T \quad (17.2)$$

Skalarprodukt

(Summe der Fehlerquadrate, nur Schwankungen interessieren)

17.1.2 Zur EOF-Analyse

EOF Analyse ist eine Technik, um Muster simultaner Variation zu identifizieren.

Warum machen wir eine EOF Analyse? Das ist das was wir immer machen können, wenn wir gar keine Ahnung vom System haben. Um System vom hochdimensionalem auf was niedrigdimensionales zu bringen (vllt sogar 1.dim). Wenn man sich nur die Variabilität interessiert, zB. für Frühwarnung oder um überhaupt eine Vorhersage machen zu können, dann kann man runter gehen zB auf 14 Dimensionen.

EOF analysis is a technique that is used to identify patterns of simultaneous variation. To demonstrate the concept we let $\vec{x}_t$ represent the $m = 9$ level geopotential height profile observed at time t . The mean profile is denoted by $\hat{\mu}$ and to describe the variability we form the *anomalies*

$$\vec{x}'_t = \vec{x}_t - \hat{\mu}.$$

These anomalies are then *expanded* into a finite series

$$\vec{x}'_t = \sum_{i=1}^k \hat{\alpha}_{i,t} \hat{e}^i \quad (13.1)$$

with time coefficients $\hat{\alpha}_{i,t}$ and fixed *patterns* $\hat{e}^i$.

much less than m . The patterns are chosen to be *orthogonal* so that optimal coefficients $\hat{\alpha}_{i,t}$ are obtained by simply projecting the anomalies $\vec{x}'_t$ onto the patterns $\hat{e}^i$. Moreover, the patterns can be specified such that the *error*

$$\sum_t \left(\vec{x}'_t - \sum_{i=1}^k \hat{\alpha}_{i,t} \hat{e}^i \right)^2$$

is minimal. The lag-0 sample cross-correlations of

13.1.2 The First EOF. The first step is to find one 'pattern' $\vec{e}^1$, with $\|\vec{e}^1\| = 1$, such that

$$\epsilon_1 = \mathcal{E} \left(\|\vec{X} - \langle \vec{X}, \vec{e}^1 \rangle \vec{e}^1\|^2 \right) \quad (13.2)$$

is minimized.⁹ Equation (13.2) describes the projection of the random vector $\vec{X}$ onto a one-dimensional subspace spanned by the fixed vector

X sehr hochdimensional
trick:
Vektor entwickeln
nach basis vektoren
mit kleiner Zahl von
Basisvektoren

13.1.4 Theorem. The following theorem results from the analysis presented so far.

Let $\vec{X}$ be an m -dimensional random vector with mean $\vec{\mu}$ and covariance matrix Σ . Let $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$ be the eigenvalues of Σ and let $\vec{e}^1, \dots, \vec{e}^m$ be the corresponding eigenvectors of unit length. Since Σ is Hermitian, the eigenvalues are non-negative and the eigenvectors are orthogonal.

(i) The k eigenvectors that correspond to $\lambda_1, \dots, \lambda_k$ minimize

$$\epsilon_k = \mathcal{E}(\|\vec{X} - \vec{\mu} - \sum_{i=1}^k \langle \vec{X} - \vec{\mu}, \vec{e}^i \rangle \vec{e}^i\|^2). \quad (13.3)$$

Bei uns genügt 'symmetrisch'.

(i) The k eigenvectors that correspond to $\lambda_1, \dots, \lambda_k$ minimize

$$\epsilon_k = \mathcal{E}(\|\vec{X} - \vec{\mu} - \sum_{i=1}^k \langle \vec{X} - \vec{\mu}, \vec{e}^i \rangle \vec{e}^i\|^2). \quad (13.3)$$

$$(ii) \quad \epsilon_k = \text{Var}(\vec{X}) - \sum_{i=1}^k \lambda_i. \quad \text{gesamt} \quad (13.4)$$

$$(iii) \quad \text{Var}(\vec{X}) = \sum_{i=1}^m \lambda_i. \quad \text{gesamt} \quad (13.5)$$

Optimale Anpassung
Minimierung umgehen wenn auf eigenes
System sehen

Varianz: Summe der
Eigenwerte aus Kovarianz Matrix
→ Eigenwerte = Essenz

- D.h. man kann die Minimierung umgehen, wenn man einfach mit den Eigenvektoren der Kovarianzmatrix arbeitet, beginnend mit demjenigen des größten Eigenwertes
- Man projiziert die hochdimensionale Zeitreihe auf die in diesem Sinne führenden Eigenvektoren der Kovarianzmatrix und erhält so eine niedrigdimensionale Zeitreihe.
- So kann man in der Praxis eine mathematische Analyse von 'schnell' und 'langsam' bei der Dimensionsreduktion umgehen.
 - Dann ist aber auch die Aussagekraft des niedrigdimensionalen Modells geringer.

17.1.3 EOF Analyse im Kontext Sattelknoten-Bifurkation

- Trend abziehen
- $V := \langle yy^T \rangle$ räumliche Kovarianzmatrix, entlang der Zeitachse erheben
- $U^T D U := V$ Diagonalisierung der symmetrischen Matrix V
- Beginnend mit den größten D_{ii} : ausreichend viele auswählen, so dass Q % der Varianz aufgespannt wird.
- Auf den zugehörigen Unterraum der Eigenvektoren projizieren

17.1.4 Ablaufplan EOF-Analyse

Eigenwertzahl = Dimension
 $\rightarrow$ Kovarianzmatrix immer symmetrisch

1. Kommt zum Einsatz bei (zu) hochdimensionaler räumlicher Zeitreihe: Verfahren zur Dimensionsreduktion
2. Zeitreihe im Raum aufgespannt mit ganzen vielen Variablen drin
- 3. Aus der Zeitreihe die räumliche Kovarianzmatrix schätzen
4. Welche Räume verhalten sich ähnlich
5. Mittelwert schätzen: $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \vec{X}_i$
6. Kovarianz Matrix schätzen: $\hat{C} = \frac{1}{n-1} \sum_{i=1}^n (\vec{X}_i - \hat{\mu})(\vec{X}_i - \hat{\mu})^T$
7. Für C Eigenvektoren (auf die Länge 1 normiert) und Eigenwerte bestimmen (Standardroutinen im Statistikprogramm). Ihre Zahl heißt K_{max} (=räumliche Dimension)
8. Diese so sortieren, dass die zugehörigen Eigenwerte mit dem größten beginnen und dann monoton fallen.
9. Die sortierten Eigenvektoren heißen $e^1, e^2, e^3, \dots$
10. Die zugehörigen Eigenwerte heißen $\lambda_1, \lambda_2, \lambda_3, \dots$
11. Festlegen, welchen Anteil R der Varianz der Zeitreihe man mit reduzierter Zeitreihe erklären möchte. R zwischen 0 und 1.
12. Daraus festlegen, wie viele Eigenvektoren gebraucht werden: $\frac{\sum_{k=1}^K \lambda_k}{\sum_{k=1}^{K_{max}} \lambda_k} \geq R$, k möglichst klein wählen (meistens liegt K zwischen 1 und 20).
13. Zeitreihe der Schwankungen um den Mittelwert $x'_t = x_t - \mu$ auf die Eigenvektoren $e^1, e^2, e^3, \dots, e^k$ projizieren: $\alpha_{k,t} = \langle x'_t | e^k \rangle$. (=Skalarprodukt zwischen zwei Vektoren)
14. Fasst man für die verschiedenen k 's die Zeitreihe in α zusammen, erhält man eine Vektor-Zeitreihe α_t in $K \ll K_{max}$ Dimensionen.

Man hofft so, dass sich der wesentliche Teil der Dynamik in diesen wenigen Dimensionen einfangen ließ.

17.2 Autokovarianz-Funktion

(Einheit von X_t^2 : $\gamma(\tau) = Cov(X_t, X_{t+\tau})$,

Auto-Korrelations-Funktion (dimensionslos): $\rho(\tau) = \frac{\gamma(\tau)}{\gamma(0)}$. τ nennt man lag. Die beiden Funktionen haben die selbe Form, aber unterschiedliche Einheiten.

17.2.1 Autokorrelation von weißem Rauschen

Die Elemente von weißem Rauschen sind unabhängig, daher folgt für die Auto-Korrelationsfunktion: sie ist 1 wenn $\tau = 0$ ist und 0 in allen anderen Fällen.

17.2.2 Auto-Korrelation eines AR1 Prozesses

$\rho(\tau) = e^{(lnc)\|\tau\|/\Delta t}$. Das ist äquivalent zu: $\rho(\Delta n) = c^{\|\Delta n\|} = e^{(lnc)\|\Delta n\|}$.

Das bedeutet, dass das Gedächtnis eines AR1-Prozesses exponentiell mit der Zeit zerfällt.

17.2.3 Schätzer

Schätzer der Auto-Korrelations Funktion $\rho(\tau)$: $r(\tau) = \frac{c(\tau)}{c(0)}$, $c(\tau)$ ist die sample Auto-Kovarianz-Funktion: $c(\tau) = \frac{1}{T} \sum_{t=\|\tau\|+1}^T X'_{t-\|\tau\|} X'_t$.

Die sample Auto-Kovarianz Funktion wird 0 gesetzt, für $\|\tau\| \geq T$.

17.2.4 Wie schätzt man den Propagator c

$$\hat{c} = \frac{\langle x_n x_{n+1} \rangle}{\langle x_n^2 \rangle} = \frac{\sum_{n=1}^{N-1} x_n x_{n+1}}{\sum_{n=1}^N x_n^2},$$

mit $Var(\hat{c}) \approx \frac{1}{N}(1 - c^2)$

17.2.5 Ist Zeitreihe unkorreliert - Durbin-Watson Test

$$d = \frac{\sum_{t=1}^{T-1} (X'_{t+1} - X'_t)^2}{\sum_{t=1}^T (X'_t)^2}$$

Dann haben wir perfekte zeitliche Korrelation für $d = 0$, zeitlich unkorreliert für $d = 2$ und perfekte zeitliche Anti-Korrelation für $d = 4$.

Es handelt sich um einen Standardtest, um Residuen bei linearer Regression zu prüfen.

Besonderheit: Bei perfekter Unabhängigkeit strebt die Statistik gegen 2. Für eine vorgegebene Signifikanz werden jedoch nach oben und unten keine Schwellwerte für Ablehnung von unkorreliert angegeben, sondern Intervalle. Liegt die Statistik unterhalb des unteren Intervalls, muss unkorreliert verworfen werden. Liegt die Statistik innerhalb der unteren Intervalls, müssen weitere Tests nachgeschaltet werden. Analoges gilt für das obere Intervall.

17.2.6 Nachtrag: Wie prüft man, ob ein Fixpunkt stabil ist?

Betrachtet wird die Dynamik des Systems für kleine Auslenkungen aus dem Fixpunkt ohne Rauschen.

Klein bedeutet hier, dass die Dynamik gut durch eine Taylor-Entwicklung 1.Ordnung um den Fixpunkt herum beschrieben wird:

$$\frac{d\delta x}{dt} \approx -A\delta x.$$

Stabil bedeutet dann, dass das System nach einer Auslenkung asymptotisch in den Fixpunkt zurückkehrt.

Für den Spezialfall einer Dimension: $\frac{d\delta x}{dt} \approx -a\delta x$.

Dann ist $\delta x(t) \approx \delta x(0)e^{-at}$. Daraus erkennt man, dass ein 1.dim Fixpunkt genau dann stabil ist, wenn $a > 0$, also $-a < 0$.

Für den Allgemeinen Fall gilt dann: Ein Fixpunkt ist genau dann stabil, wenn alle Eigenwerte der Matrix $-A$ negativ sind.

Achtung: Dies bedeutet keinesfalls, dass dann eine Störung sofort abklingen muss. Bei nicht-normalen Matrizen kann es sein, dass Störungen zunächst anwachsen, obgleich alle Eigenwerte negativ sind. So kann Turbulenz erklärt werden. Das System ist eigentlich stabil, aber kleine Störungen führen zunächst zum Anwachsen und geraten dann in den nichtlinearen Bereich, wo Obiges dann nicht mehr gilt.

18 Altklausurfragen

18.1 Grundlagen der Statistik - Welche der Aussagen sind korrekt?

1. Induktive Statistik hilft, eine Beziehung zwischen Beobachtungen und verborgenen Modellen herzustellen. - **RICHTIG**
2. Mit Hilfe statistischer Methoden lassen sich Hypothesen beweisen - **FALSCH**
3. Der Mittelwert ist das erste zentrierte Moment einer Verteilung - **FALSCH**
4. Der Mittelwert ist das erste Moment einer Verteilung **RICHTIG**
5. Im Kontext Konfidenzintervalle lassen sich in manchen Fällen nur Untergrenzen für die Konfidenz angeben. Um dieses Problem zu überwinden wurde Bootstrapping erfunden. - **FALSCH**
6. Es gibt keinen erwartungstreuen Varianzschätzer - **FALSCH**
7. Bei symmetrischen eingipfeligen Wahrscheinlichkeitsdichteverteilungen sind Median, Mittelwert und Modus identisch - **RICHTIG**
8. Die ungeraden zentralen Momente einer Gaußverteilung verschwinden - **RICHTIG**
9. Die Varianz der Summe zweier Zufallsgrößen ist gleich der Summe der Varianzen dieser Zufallsgrößen, wenn die beiden Zufallsgrößen unabhängig sind - **RICHTIG**
10. Die Varianz der Summe zweier Zufallsgrößen kann von der Summe der Varianzen der beiden Zufallsgrößen abweichen - **RICHTIG**
11. Der Mittelwert der Summe zweier Zufallsgrößen ist gleich der Summe der Mittelwerte dieser Zufallsgrößen - **RICHTIG**
12. Der Median einer Verteilung ist der Wert, an dem die kumulierte Verteilung $\frac{1}{2}$ annimmt - **RICHTIG**
13. Der zentrale Grenzwertsatz weist der Gaußverteilung eine Sonderrolle zu - **RICHTIG**
14. $Var(aX) = a^2 Var(X)$, a ist Konstante, X ist Zufallsgröße - **RICHTIG**
15. Multivariate lineare Regression kann auch nichtlineare Fitfunktionen verarbeiten - **RICHTIG**
16. Statistik liefert einen Satz an Methoden um von Stichproben auf nicht direkt beobachtbare Eigenschaften von Grundgesamtheiten zu schließen - **RICHTIG**
17. Die so gewonnenen Aussagen sind **probabilistischer** Natur **RICHTIG**
18. Die Varianz ist das zweite zentrierte Moment einer Verteilung **RICHTIG**
19. Die Varianz ist das zweite Moment einer Verteilung **FALSCH**
20. Der Median einer Verteilung ist der Wert, an dem die Dichteverteilung ihr Maximum annimmt - **FALSCH**
21. Statistik begann als Hilfswissenschaft, um mit wiederholten Beobachtungen möglichst geschickt umzugehen und so die empirischen Wissenschaften zu unterstützen **RICHTIG**
22. Stochastische Prozesse sind zufallsgetriebene Prozesse **RICHTIG**
23. Die Poissonverteilung lässt sich als Grenzfall der Binomialverteilung deuten. **RICHTIG**
24. Zu jedem Schätzer lässt sich ein Konfidenzintervall konstruieren, dem eine exakte Konfidenzwahrscheinlichkeit entspricht. **FALSCH**
25. Bootstrapping erlaubt die numerische Konstruktion approximierter Konfidenzintervalle. **RICHTIG**
26. Eine Darstellung des Zusammenhangs $y = ax^2$ ist im Rahmen linearer Regression nicht möglich. **FALSCH**

27. Optimal Fingerprinting kann als verallgemeinerte lineare Regression gedeutet werden.
RICHTIG

18.2 Konfidenzintervalle

Noch dazu: Wenn ich Konfidenzintervall so angeben soll, dass mit 100 % Sicherheit der wahre Wert drin liegt, dann geb ich einfach das unendliche Intervall von $-\infty$ bis $+\infty$ an.

1. Erläutern Sie das Konzept eines Konfidenzintervalls (2P.)
 2. Beschreiben Sie, wie Sie aus Ihrer Stichprobe des Umfanges n einen Schätzwert für den Erwartungswert einer Gaußverteilung μ und ein **exaktes** Konfidenzintervall zum Konfidenzniveau Q erhalten (3P.)
 3. Beschreiben Sie die Rolle der Näherungsformel für ein Konfidenzintervall in diesem Zusammenhang: Wann gilt sie, für welche Konfidenz und wann gleichen sich beide Verfahren an? (2P.)
 4. Wie kann es passieren, dass für Merkmale mancher Verteilungen nur Untergrenzen der Konfidenzen angegeben werden können? (2P.)
 5. Konfidenzintervall vereinfachen für 68 und 95 %.
 6. Stellen Sie sich vor, eine in der Natur existierende Größe μ kann nicht direkt beobachtet werden, sondern ist durch gaußsches weißes Rauschen mit Standardabweichung σ überlagert. Begründen Sie warum die beobachteten Werte gaußverteilt sind mit Mittelwert μ und Standardabweichung σ .
 7. statt Aufgabe 5.: Für welche beiden näherungsweise Konfidenzniveaus Q können sie in 6. die Konstruktion von Konfidenzintervallen näherungsweise vereinfachen? Beschreiben Sie dieses Verfahren.
 8. Wie skaliert asymptotisch die Breite ihres Konfidenzintervalls mit n ?
1. Wenn man wissen möchte, wie sicher der **beste Wert** ist, den die bisherigen Methoden aus der Messreihe generiert haben nutzen wir das sogenannte Konfidenzintervall. Unter dem Konfidenzintervall, abgekürzt auch KI, ist ein **statistisches Intervall** zu verstehen, das die **Lage eines wahren Parameters** einer Grundgesamtheit mit einer **gewissen Wahrscheinlichkeit** lokalisieren soll. Häufig nutzen wir dafür **2 Standardabweichungen**, welche dann einem Konfidenzintervall von **95 %** entsprechen. Ist ein Intervall mit einer **Ober- und einer Untergrenze**. Gibt die Wahrscheinlichkeit an, dass das **Intervall den wahren Wert einschließt**. Zu betonen: der wahre Wert bewegt sich nicht stochastisch, der ist fest, das Intervall bewegt sich. Die Bestimmung der Intervallgrenzen berücksichtigt die angenommene Verteilung der Zufallsgröße.
2. $x = [x_1, \dots, x_n]$ die x_i sind dabei iid.
Wir wissen dass das **arithmetische Mittel** ein erwartungstreuer Schätzer für μ ist: $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$.
Wir wissen ferner, dass $\hat{\mu}$ **t-verteilt** ist. Das heißt die Grenzen für das KI sind wie folgt:
 $\hat{\mu} = \pm \frac{t_{\alpha, n-1} \hat{s}}{\sqrt{n}}$.
Wobei $\hat{s}^2$ der erwartungstreue Schätzer für die Varianz ist: $\hat{s}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{\mu})^2$.
3. Diese Formel liefert ein genähertes Konfidenzintervall für den **Erwartungswert einer Gaußverteilung**. Gilt für ausreichend große $n \geq 30$. Zugehörige Konfidenz ist **68%**, da a hier scheinbar $=1$. Beide Verfahren gleichen sich mit immer größeren n immer mehr an und wären für $n = \infty$

identisch.

4. Zum einen kann das nur bei diskreten Verteilungen passieren, weil wir diskrete Ergebnisse haben, nicht z.B. bei einer Gaußverteilung. Wir können hier kein glattes Konfidenzniveau von 95% erreichen. Da ist der Formalismus überfordert. Z.B. bei der Binomialverteilung. Stichwort: Piercon-Clopper Werte.

5. Nur 1 oder 2 für a einsetzen.

6. $x = \mu + z$ ist Normalverteilt mit Mittelwert 0 und Standardabweichung σ .

Dann gilt für den Erwartungswert von x: $E(x) = E(\mu + z) = \mu + 0 = \mu$.

Für die Varianz von x gilt dann: $Var(x) = Var(\mu + z) = Var(z) = \sigma^2$.

$\sqrt{Var(x)} = \sigma$.

Die Zufallsgröße des Rauschterms wird additiv mit einer Konstanten kombiniert. Daraus ergibt sich eine verschobene Verteilung die ansonsten die selben Eigenschaften aufweist. x ist also Normalverteilung mit Mittelwert μ und Standardabweichung σ .

7. Statt der t-Verteilung kann auch ein Multiplikator für die Standardabweichung verwendet werden:

$\hat{\mu} \pm \frac{a\hat{\sigma}}{\sqrt{n}}$, wobei $a = 1$ in etwa $p \approx 68\%$ entsprechen und $a = 2$ 95 Prozent.

Allerdings steigt mit sinkendem n der Fehler.

8. $\lim_{n \rightarrow \infty} 2 \cdot \frac{a \cdot \frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{x})^2}{\sqrt{n}}$.

Und $\lim_{n \rightarrow 0} 2 \frac{a\hat{\sigma}}{\sqrt{n}}$.

Mit zusätzlichen Beobachtungen sinkt somit die Breite des KI.

18.3 Skalierung (2P.)

Gehen Sie von einer Zufallsgröße X aus. Erzeugen Sie die neue Zufallsgröße Z , indem Sie die ursprüngliche Zufallsgröße X n -mal unabhängig addieren. Leiten Sie analytisch her, wie die relative Unsicherheit (Standardabweichung dividiert durch Erwartungswert) von Z mit n skaliert.

Antwort:

$$\begin{aligned}
 Z &:= \sum_{i=1}^n X_i & X &:= X_i \stackrel{iid}{\sim} F \\
 \text{Var}(Z) &= \text{Var}\left(\sum_{i=1}^n X_i\right) \\
 &= \sum_{i=1}^n \text{Var}(X_i) \\
 &= n \cdot \text{Var}(X) \\
 E(Z) &= E\left(\sum_{i=1}^n X_i\right) \\
 &= n \cdot E(X) \\
 \frac{\sqrt{n} \cdot \sqrt{\text{Var}(X)}}{n \cdot E(X)} &= \frac{1}{\sqrt{n}} \frac{\text{Var}(X)}{E(X)} \quad \square \\
 \frac{n^{\frac{1}{2}}}{n^1} &: n^{\frac{1}{2}} \cdot n^{-1} = n^{-\frac{1}{2}}
 \end{aligned}$$

$$\begin{aligned}
 X &: X_i \stackrel{iid}{\sim} F \\
 Z &: \sum_{i=1}^n X_i \\
 \text{Var}(Z) &= \text{Var}\left(\sum_{i=1}^n X_i\right) \\
 &= \sum_{i=1}^n \text{Var}(X_i) \\
 &= n \cdot \text{Var}(X) \\
 E(Z) &= E\left(\sum_{i=1}^n X_i\right) \\
 &= n \cdot E(X) \\
 \Rightarrow \frac{\sqrt{n} \cdot \sqrt{\text{Var}(X)}}{n \cdot E(X)} &= \frac{1}{\sqrt{n}} \frac{\text{Var}(X)}{E(X)}
 \end{aligned}$$

$$\frac{\sqrt{n}}{n} = \frac{n^{\frac{1}{2}}}{n^1} = n^{\frac{1}{2}} \cdot n^{-1} = n^{-\frac{1}{2}} = \frac{1}{\sqrt{n}}$$

18.4 Lineare Regression

1. Was versteht man unter linearer Regression (inklusive multivariater)? An welche exakten Voraussetzungen ist sie geknüpft? (2P.)
2. Wann sollten Sie nichtlineare Funktionen anfitten? (2P.)
3. Erläutern Sie den Zusammenhang zwischen linearer Regression und 'optimal Fingerprinting', geben Sie die entsprechende Formel an und erläutern Sie wie Sie deren Einträge bestimmen. (2P.) + Schritte des Fingerprintings
4. Es wurden zwei Konfidenzintervalle für Vorhersagen aus einfacher linearer Regression diskutiert. Bitte erläutern Sie deren Interpretation. (2P.)
5. Bitte beschreiben Sie den Gesamtprozess einer linearen Regression, inkl. der vorgeschalteten Tests. (2P.)
6. 2 Beispiele für Fehlanwendungen Linearer Regression.
7. Warum wird Intervall kleiner wenn Messreihe länger wird.

8. Erläutern Sie warum im Mittel Ihre Konfidenzintervalle umso kleiner werden, je länger die Messreihe ist auf der sie basieren. (KI für Vorhersage bei univariater linearer Regression)
9. Geben Sie die Formeln für die Steigung bei univariater linearer Regression und deren Konfidenzintervall an.
10. Geben Sie eine Formel für eine Vorhersage mittels linearer Regression und deren Konfidenzintervall an und interpretieren Sie letztere.

1. Lineare Regression versucht, eine Datenreihe y aus einer Datenreihe x oder mehreren Datenreihen $x_1, x_2, x_3, \dots$ durch einen linearen Ansatz zu erklären. Abweichungen zwischen diesem linearen Modell und y werden durch einen Rauschterm erklärt. Diese Abweichungen werden Residuen genannt. Die Entwicklungskoeffizienten bestimmt man, indem man die Summe der Quadrate der Residuen minimiert. Dieses gefittete lineare Modell kann genutzt werden um (1) Daten vereinfacht darzustellen, (2) zu prüfen, ob es einen von Null verschiedenen Trend gibt oder (3) y -Werte vorherzusagen. Falls die Residuen unabhängig und identisch gaußverteilt sind, können die in der Vorlesung angegebenen Formeln für Konfidenzintervalle verwendet werden.

iid

Voraussetzungen: 1. Die Stichprobe der Variablen muss derart sein, dass die Residuen iid sind, 2. Das heißt die Stichprobenwerte müssen unabhängig, aus der selben Verteilung gezogen sein.

bei multivariater zusätzlich: unabhängige Variablen sollten untereinander unabhängig sein.

2. Wenn uns nur sehr kleine Abweichungen um einen bestimmten Punkt interessieren.

3. Mit Hilfe von Optimal Fingerprinting wird versucht zu bestimmen, welche Ursachen hinter einem Signal in der Natur liegen.

Hierbei wird das Natursignal mit y aus 4.1. mit verschiedenen Mustern, die sich in einem Erdsystemmodell herausbilden, wenn man das Natursystem mit unterschiedlichen menschengemachten Substanzen traktiert.

Eine (erweiterte) lineare Regression liefert dann Entwicklungskoeffizienten, die den Einfluss der einzelnen Agenten auf das Natursystem ausdrücken.

Andere Art Zusammenhang zu erklären: Optimal Fingerprinting ist eine Anwendung der linearen Regression. Ist eine multiple lineare Regression, in der alle möglichen Treiber der globalen Temperatur als unabhängige Variablen eingesetzt werden. Die Koeffizienten geben dann den jeweiligen marginalen Beitrag der Treiber zur Temperatur an.

Die Formel auf S.63, 14.6 liefert diese Koeffizienten. X ist die Designmatrix. Spalte 1 besteht aus lauter Einsen. Die übrigen Spalten werden durch $x_1, x_2, x_3, \dots$ aufgefüllt.

C ist die Kovarianzmatrix. Sie wird benötigt, wenn die Residuen korreliert sind, Sie kommt in der linearen Regression von 4.1. nicht vor. Sie wird nach 5.13. aus von Storch und Zwiers (Folie 49, 21.6) bestimmt.

Zusätzlich: Hypothesentests auf die Koeffizienten können verwendet werden, um die Hypothese, dass bestimmte Treiber keinen Einfluss haben, mit einer gewählten Fehlerwahrscheinlichkeit zu widerlegen.

Schritte:

- Identifikation der Treiber
- multiple Ols der räumlichen Muster der Treiber
- Aus OLS erhält man Koeffizienten.
- Für Koeffizienten berechnen wir Konfidenzbereiche.

4. Nur eins und nicht zwei Konfidenzintervalle. Da ist die gesamte Unsicherheit drin. Kommt von der Bestimmung der Geraden. Haben immer den Rauschterm. Wenn wir eine Vorhersage mit unserer Gerade machen, dann geht ein Trichter auf. Das ist ein parabolischer Trichter. Geht in einen linearen Trichter über. Wenn wir mit dem Modell sehr sehr weit in die Zukunft gehen, dann geht die Unsicherheit immer weiter auf, je weiter wir uns von den Daten entfernen. Trichter ist Ausdruck davon, dass man selbst bei einem perfekten Modell, nicht genau weiß welches lineare Modell genau das richtige ist.

5.

- Daten plotten, ersten Eindruck gewinnen, welches Modell passen könnte.
- Lineare Regression durchführen und das gefittete Modell in die Daten mit hineinplotten, dazu: Formel aufstellen, a, b schätzen. Passt das Modell?
- Residuen bestimmen und plotten (alles was durch lin. Fit nicht erklärt wird), Verhalten sie sich so, dass sie aus einer identischen gaußschen Verteilung stammen? Sind sie nach Auge unabhängig? Alarm wenn die Residuen zB Parabel ergeben, dann müsste die Fitfunktion verändert werden, evtl. müsste Rauschmodell erweitern werden, wenn Residuen sich Augenaussehend um x-Achse verteilen, also Parabel auf beiden Seiten der x-Achse, symmetrisch. Zahl der Fitparameter sollte um mind. eine Größenordnung unter n liegen.
- Falls Residuen nach Auge ok, folgen 2 Tests: (i) Test auf Gauß: Chi 2 Test aber nur mit Freiheitsgraden k-2, statt wie sonst k-3, (ii) Test auf Unabhängigkeit: Durbin-Watson Test.
- Modell kann grundsätzlich für Vorhersagen genutzt werden, allerdings können die Formeln für Konfidenzintervalle oder Trendbestimmungen nur verwendet werden, falls 4. erfolgreich war.
- Falls nicht Gauß, kann immernoch Bootstrapping verwendet werden, um Konfidenzintervalle zu bestimmen.
- Falls Bedingung nach Unabhängigkeit verletzt wurde, kann Fingerprinting eingesetzt werden.
- Wenn beides verletzt, müssen komplexere Verfahren zum Einsatz kommen.

6.

- Bei kleinen Stichproben lassen sich gegebenenfalls Zusammenhänge zwischen nicht linearen Variablen finden
- Nicht immer ist der Zusammenhang linear
- Wichtige Variable vergessen kann Koeffizienten verzerren
- Residuen nicht iid

7. Logik: Desto mehr Messwerte haben, desto mehr Sicherheit haben wir, unser benötigtes KI wird somit kleiner.

8.

d) Breite des KI

$$Z \cdot t_{1-p, n-2} \cdot \hat{\sigma}_\varepsilon \cdot \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}}}$$

$$\lim_{n \rightarrow \infty} Z \cdot t_{1-p, n-2} \cdot \hat{\sigma}_\varepsilon \cdot \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}}} = Z \cdot t_{1-p, \infty} \cdot \hat{\sigma}_\varepsilon \cdot \sqrt{1 + \frac{(x - \bar{x})^2}{S_{xx}}} = \text{const}$$

$\xrightarrow{\text{für } p=0.95} \rightarrow 2$
 $\xrightarrow{\quad} \rightarrow \hat{\sigma}_\varepsilon$

$$\lim_{n \rightarrow \infty} \hat{\sigma}_\varepsilon = \frac{1}{n-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sigma_\varepsilon$$

Und für kleine n ist der Term $1/n$ groß, das heißt mit steigendem n sinkt der Beitrag für die Breite des Ki, das Ki wird somit schmaler. Je mehr Daten wir haben, desto weniger Unsicherheit haben wir, desto kleiner wird unser Ki.

9. Siehe Zusammenfassung Teil KI für Vorhersage.

10. Formel siehe andere Klausuraufgabe.

18.5 AR1-Prozesse und Bifurkationen

1. Wie bestimmen Sie an einer gewöhnlichen Differentialgleichung erster Ordnung die Gleichgewichtspunkte? Bitte unterstützen Sie Ihre Ausführungen durch die entsprechenden analytischen Ausdrücke. (2P.)
2. Was ist eine Bifurkation? (1P.)
3. Für welche u kommt es zu einer Bifurkation?
4. Zusammenhang DGL und AR1-Prozesse
5. Bitte erläutern Sie was ein AR1-Prozess ist und warum ihm eine zentrale Rolle eingeräumt wird. (2P.)
6. Erläutern Sie analytisch den Zusammenhang zwischen Bifurkation und dem Propagator c des angenäherten AR1-Prozesses. (2P.)
7. Geben Sie die Definition der Autokorrelationsfunktion eines AR1-Prozesses an und diskutieren Sie deren anschauliche Bedeutung am Beispiel zweier unterschiedlicher stochastischer Prozesse. (2P.)
8. Stellen Sie sich vor, Sie möchten eine Stufe genauer sein, als ein AR1-Prozess dies zulässt: $y_{n+1} = cy_n + \varepsilon y_n^2 + \eta_n$. Gegenüber einem AR1-Prozess tritt also der quadratische Term hinzu. Welches Potential entspricht diesem Prozess? Wie lassen sich hier die unbekannten Koeffizienten aus einer Zeitreihe bestimmen? (3P.)
9. Welcher funktionale Zusammenhang beschreibt die Autokorrelationsfunktion eines AR1 Prozesses?

1. Ein Gleichgewicht stellt sich ein, wenn der Prozess stationär wird, wir also keine Veränderung mit der Zeit mehr haben. Heißt wir haben einen Fixpunkt der sich nicht bewegt, und wenn er sich doch bewegt, dann ist es nur ein bisschen Rauschen und wenn irgendwer das System auslenkt, kehrt es von selbst wieder zurück.

Wir setzen also die Veränderung der Funktion mit der Zeit gleich 0 und stellen dann nach ... um.

2. Eine Bifurkation ist die Änderung der Anzahl der stabilen Zustände eines Systems.

3. In 2. bestimmen wir 2 Fixpunkte. Da eine Bifurkation die Änderung der Anzahl der Fixpunkte ist, setzen wir die beiden gleich und haben somit nur noch einen Fixpunkt. Das ganze stellen wir dann nach u um. (Wir erhalten $1/4$)

4. Ein Ar1 Prozess ist eine zeitliche Diskretisierung eines durch eine DGL beschriebenen kontinuierlichen Prozesses. Und man kann Koeffizienten von Ar Prozessen finden, sodass der Ar Prozess dann den selben Mittelwert und die selbe Varianz hat wie der kontinuierliche Prozess hat und als Approximierung davon verwendet werden kann.

5. Für kleine Bewegungen um einen Fixpunkt kann ein Ar Prozess ein viel komplexeres System befriedigend imitieren. Kennzahlen von Ar Prozessen, hier der Propagator c , haben universelle Eigenschaften in der Nähe von Bifurkationen (geht gegen 1).

6. Der Zusammenhang besteht darin, dass der Propagator c sich der 1 annähert, je weiter wir uns der Bifurkation annähern. Wenn wir uns auf der Bifurkation befinden, wird der Propagator $c = 1$. Dann liegt die Brownsche Bewegung vor.

Äquivalent geht α gegen 0 (weil $1 - \alpha = c \alpha$ ist die Rückstellkraft). Das ist gleichbedeutend mit einem flacher werdenden Potential.

Da bei der Bifurkation die zwei Fixpunkte, das Tal und der Berg, im Potential zusammenwachsen, ist an der Bifurkation das Potential des einen Fixpunktes (gibt nur noch einen) flach. Das heißt $\alpha = 0$, das heißt $c = 1$.

($c = 1 - a\Delta t$. Hier sind wir im Diskreten. Wenn wir mit dem Diskreten arbeiten, sind wir in den AR Welt, oder im Kontinuierlichen, da gibt es dann keinen AR-Prozess)

7. Hier müsste es wieder reichen, die Funktion aufzuschreiben (ist diskret).

Die Rate mit der ACF abklingt hängt mit dem Gedächtnis der Zeitreihe zusammen, also mit c des AR Prozesses: große c (nahe aber kleiner 1) stehen für ein langes Gedächtnis, also langsames Abklingen. Und kleine c (nahe aber größer 0) haben ein kurzes Gedächtnis, also schnelles Abklingen. Bei $c = 0$ haben wir gar kein Gedächtnis.

Prozess der schnell abklingt: Wettervorhersage, Temp meines Tees in einer normalen Tasse, Einfluss von Nachrichten auf Aktienkurse

Prozess der langsam abklingt: Teich der fast kippt, aber noch nicht ganz braucht auch lange um wieder in sein Gleichgewicht zu kommen, Tiere wie Elefanten die sehr langsame Fortpflanzungszyklen haben

8. Wir wollen Änderung von y mit der Zeit also $y_{n+1} - y_n = (1 - c)y_n + \epsilon y_n^2 + \eta$. Das Potential ist dann das Integral der Gleichung. Per Konvention kommt ein Minuszeichen vor das Potential, das dafür sorgt, dass stabile Fixpunkte Täler sind.

Wie bestimmt man dann die Koeffizienten c und ϵ ?

Man stellt eine Schätzgleichung auf: $y_{n+1} = \beta_1 y_n + \beta_2 y_n^2$ und können dann eine multiple Regression machen, wobei die Autokorrelation der Residuen ein Problem zu sein scheint.

9. Autokovarianzfunktion: $c(\tau) = \frac{1}{T} \sum_{t=\tau+1}^T y_{t-\tau} y_t$ (falsch, siehe Abschnitt Autokorrelation)

Autokorrelationsfunktion: $r(\tau) = \frac{c(\tau)}{c(0)}$

Gesetz: $r = \exp(\ln(c))\tau$ (falsch, siehe Abschnitt Auto-Korrelation)

Je größer c , desto länger braucht das Abklingen in der Autokorrelationsfunktion.

18.6 Bootstrapping

Bitte beschreiben Sie ein Bootstrapping-Verfahren und erläutern Sie die Vor- und Nachteile gegenüber Nicht-Bootstrapping-Ansätzen.

Antwort: Ist ein Verfahren zum Bestimmen von Konfidenzintervallen und basiert auf der Wiederholung der Schätzfunktion auf einer Surrogatstichprobe, die aus der ursprünglichen Stichprobe gezogen wird. Es werden viele Wiederholungen benötigt.

Vorteil: Funktioniert auch in Fällen wo keine Verteilung aus der Analysis bekannt ist.

Nachteil: Der numerische Aufwand kann prohibitiv sein.

Die Ursprungsstichprobe muss bestimmte Eigenschaften haben, bzw. bestimmten Annahmen genügen: Die Beobachtungen müssen unkorreliert (bzw. muss iid sein) sein (mit Zeitreihe geht es also eventuell nicht), Originalstichprobe muss groß genug sein.

18.7 Hypothesentests

1. Erläutern Sie das Konzept eines Hypothesentests
2. Erläutern Sie das Konzept des Fehlers 1. Art
3. Erläutern Sie das Konzept des Fehlers 2. Art

1. Wir wollen mit einer bestimmten Wahrscheinlichkeit für den Fehler 1. Art eine Hypothese widerlegen. Wir wollen also eine Teststatistik so konzipieren, dass eine Aussage über die Wahrscheinlichkeit gemacht werden kann, obwohl das ganze nur auf einer Stichprobe basiert.

2. Ist die Wahrscheinlichkeit, die Hypothese fälschlicherweise zu widerlegen.

3. Ist die Wahrscheinlichkeit die Hypothese beizubehalten, obwohl sie falsch ist.

18.8 Chi 2 Test

Erläutern Sie die auszuführenden Schritte eines Chi 2 Tests.

Antwort:

1. Im **Definitionsraum** der Zufallsgröße **bin Grenzen** definieren
2. **Werte zählen** die jeweils in den Bin Grenzen sind
3. Damit vergleichen, wie viele unter der **hypothetischen Verteilung** jeweils innerhalb der Bingrenzen erwartet werden würden

4. aus den beiden Zahlen (wie viele da sind, wie viele erwartet würden) konstruiert man die Teststatistik
5. Den Wert vergleicht man mit dem Wert aus der Chi 2 Verteilung
6. konkrete Teststatistik schlägt man in den Unterlagen nach.

19 Persönliche Auswahl

19.1 Unsicherheiten

In der Stochastik gibt es viel Unsicherheit. Unsicherheit beschreibt dabei alle Arten des nicht-Wissens. Wir unterscheiden zwischen zwei verschiedenen Arten von UNSicherheit:

Aleatorische Unsicherheit: Diese Form der Unsicherheit ist Nicht-Wissen, dass durch stochastische Prozesse ausgelöst wird. Dabei handelt es sich um chaotische Systeme, wie zum Beispiel das Wetter. Man kann zwar Vorhersagen machen mit bestimmter Wahrscheinlichkeit, aber es besteht immer eine Unsicherheit, die nicht behoben werden kann.

epistemische Unsicherheit: Diese Form ist die andere Art der Unsicherheit, die alle weiteren Formen der Unsicherheit mit einschließt. Sie beschreibt oft eine statistische Größe, die wir nicht genau können. Durch genügend Forschung kann man diese Unsicherheit jedoch beheben. Bsp. versteckte Ostereier: wenn man lange und gründlich genug sucht, wird man alle Verstecke finden und die Unsicherheit beheben.

19.2 Poissonverteilung

Die Poissonverteilung ist eine diskrete Verteilungsfunktion, die die Verteilung von seltenen Einzelereignissen beschreibt. Sie gilt, wenn die durchschnittliche Anzahl der Ereignisse das Ergebnis einer sehr großen Zahl von Ereignismöglichkeiten und einer sehr kleinen Ereigniswahrscheinlichkeit ist. Ein Beispiel dafür wäre der Radioaktive Zerfall oder das Auftreten von Erdbeben. Wichtig dabei ist, dass die Ereignisse tatsächlich Einzelereignisse sind, das Auftreten ein Zufallsprozess ist und Proportionalität, Homogenität und Unabhängigkeit gelten.

Die Formel ist:

$$f_p(x) = \frac{(\lambda t)^x}{x!} \exp^{-\lambda t} \quad (19.1)$$

19.3 Zentraler Grenzwertsatz

Auf dem zentralen Grenzwertsatz beruht die Wichtigkeit der Normalverteilung. Man nimmt dabei an, dass die Summe einer sehr großen beliebigen (aber identisch) verteilten Zufallsvariable gegen die Normalverteilung konvergiert. Wichtig bei der Anwendung dieses Satzes ist, dass der Stichprobenumfang mindestens $n=30$ beträgt. Der Vorteil dieses Satzes ist, dass die Verteilung der Grundgesamtheit der Stichproben dabei keine Rolle spielt, sondern die Summen trotzdem normalverteilt approximiert werden können.

19.4 Jackknife Bias-Korrektur

Bei einer Stichprobe $(x_1, \dots, x_n)$ wird ein Wert a geschätzt $= \hat{a}$. Um nun eine Biaskorrektur durchzuführen, lassen wir für alle i (von 1 bis n) den Wert x_i einmal raus und berechnen von

der modifizierten Stichprobe wiederum den Wert $\hat{a}_i$. Nehmen wir nun von diesen Schätzwerten den Mittelwert $\hat{a}_j$, können wir wie folgt unseren Bias berechnen: $\Delta\hat{a} = (n-1)(\hat{a}_j - \hat{a})$. Der Bias-korrigierte Schätzer beträgt dann gerade: $\hat{a}_{kor} = \hat{a} - \Delta\hat{a}$

19.5 Schätzung mit Maximum Likelihood-Methode

Bisherige Schätzverfahren funktionieren, doch wenn man Allgemeineres über die Verteilung aussagen können will, kann man diese Methode anwenden. Die Maximum-Likelihood-Methode wird verwendet, wenn man Zufallsvariablen X aus einer Dichterverteilung mit einer unbekannten Eigenschaft a generiert und diese Eigenschaft schätzen will. Das Prinzip beruht darauf, zu schauen, bei welchem Wert für a die Wahrscheinlichkeit, die genaue Datenreihe X'' zu erhalten, am grössten ist. Man konstruiert dazu eine Max-Likelihood-Funktion $L(a; x_1, \dots, x_n) := f(x_1, \dots, x_n; a)$. Handlicher:

$$\hat{a}_{ML} := \operatorname{argmax} \ln \prod_{k=1}^n f(x_k; a) \quad (19.2)$$

Somit gilt dann auch $\hat{a}_{ML} = \operatorname{argmax} \sum_{k=1}^n \ln f(x_k; a)$, dieser Schätzer ist konsistent.

19.6 Pearson-Clopper-Werte

Die Pearson-Clopper-Werte geben die Konfidenzintervalle für bestimmte Erfolgswahrscheinlichkeiten einer Binomialverteilung an. Dabei haben wir n Versuche und x Treffer, die Erfolgswahrscheinlichkeit wird mit $\hat{p} = \frac{x}{n}$ geschätzt. Mit den gegebenen oder ermittelten Werten für x und n , geben die tabellarischen Werte von Pearson und Clopper die KI für p an. Sie garantieren immer eine exakte Untergrenze der Konfidenz.

19.7 Chi 2 Test

1. Im Definitionsraum der Zufallsgröße Bin-Grenzen definieren (in Klassen einteilen, muss den gesamten theoretischen Wertebereich abdecken)
2. Werte zählen die jeweils in den Bin Grenzen sind (Anzahl Werte, innerhalb einer Klasse)
3. Damit vergleichen, wie viele unter der hypothetischen Verteilung jeweils innerhalb der Bin-Grenzen erwartet werden würden
4. aus den beiden Zahlen (wie viele da sind, wie viele erwartet würden) konstruiert man die Teststatistik

$$c^2 = \sum_{r=1}^k \frac{(m_r - np_r)^2}{np_r} \quad (19.3)$$

5. Den Wert vergleicht man mit dem Wert aus der Chi 2 Verteilung.
6. konkrete Teststatistik schlägt man in den Unterlagen nach. $c^2 \leq \chi_\alpha^2$ bedeutet, dass die angenommene Verteilungsfunktion mit Irrtumswahrscheinlichkeit α als die Verteilungsfunktion von X angenommen werden kann. (Man braucht sie nicht zu verwerfen)

Dabei sind für die Chi 2 Werte wichtig, dass man die Irrtumswahrscheinlichkeit α kennt, und mit der Anzahl der Klassen k die Freiheitsgrade $m = k - 1 - s$ (s ist dabei die Anzahl unbekannter Parameter, bei Gauss immer $m=k-1$) bestimmen kann.

Würden Histogramm und zu prüfende Verteilung perfekt übereinstimmen, wäre $c=0$.

19.8 Durbin-Watson-Test

Der Durbin-Watson-Test ist ein Testverfahren zur Prüfung der Unkorreliertheit der Werte. Sie überprüft die serielle correlation der Regressionsresiduen.

$$d = \frac{\sum_{t=1}^{T-1} (X'_{t+1} - X'_t)^2}{\sum_{t=1}^T (X'_t)^2} \quad (19.4)$$

$d = 0$: perfekte Zeitliche Korrelation

$d = 2$: Zeitlich unkorreliert

$d = 4$: perfekte zeitliche Antikorrelation

19.9 White Noise

Weisses Rauschen ist eine unendliche Sequenz von iid normalverteilten variable mit mittelwert 0. Es ist das simpelste Beispiel eines stochastischen Prozesses. Weisses Rauschen besitzt kein Gedächtnis was bedeutet, dass für jeden Zeitpunkt t der Wert X_t komplett unabhängig von jeden anderen Element in dem Prozess ist. Der Begriff "weisses Rauschen" kommt von der Optik: Überlagerung aller möglichen Frequenzen resultiert in weisser Farbgebung, somit auch weisses Rauschen.

19.10 Motivation AR1-Prozesse

Autoregressive Modelle beschäftigen sich mit Zeitreihen, die über die Zeit von sich selbst abhängen und seriell korreliert sind. Es beschreibt also, inwiefern eine Beobachtung zum Zeitpunkt t von vergangenen Beobachtungen abhängig ist.

Dabei können diese vorherigen Beobachtungen in ganz naher oder ferner Vergangenheit liegen. Die Bestimmung des autoregressiven Modells betrachtet all diese Zusammenhänge und erstellt ein Modell, mit dem man aus den vergangenen Werten die aktuellen oder zukünftige Werte voraussagen kann. Ein autoregressiver Prozess erster Ordnung (AR(1)), ist nun ein stochastischer Prozess, dessen Realisation im Zeitpunkt t , nur von seiner mit β_1 gewichteten Realisation im Zeitpunkt $t-1$ (also ein Zeitschritt vorher), und einem weißen Rauschen ϵ_t abhängt, d.h. $X_t = \beta_0 + \beta_1 X_{t-1} + \epsilon_t$ gilt. Dieses weiße Rauschen ist der Fehlerterm, der im besten Falle iid aus einer bekannten Verteilung kommt (zB Gaussche Verteilung)

Dieser AR(1) Prozess ist in dem Sinne sehr wichtig, da in den Erdsystemwissenschaften fast alle Werte auf Zeitreihen beruhen und wir nur viele Werte aus der Vergangenheit haben. Oft werden diese langen Zeitreihen in der Erdsystemwissenschaft anschliessend auf jährliche Werte gemittelt, wodurch man mit AR-Prozessen geringer Ordnung auch schon gute Aussagen treffen kann.

Die Erde und ihr System ist sehr chaotisch und hat viele Unsicherheitsfaktoren, wodurch konkrete Voraussagen auf kleinen Skalen manchmal sehr ungenau sein kann. Über lange Zeiträume ist das System jedoch im Gleichgewicht und kann somit auf gut vorausgesagt werden. Betrachten wir das Beispielt der Jahresmitteltemperatur am Ort x . Täglich schwankt die Temperatur, es kann zu plötzlichen Hitzewellen oder Kaltgebieten kommen, doch wenn man den Mittelwert

erhebt und diesen in eine Zeitreihe über Jahre plottet, kann man klare tendenzen berechnen, welche nur durch Rauschen noch verändert werden.